creative commons

COMMONS DEED

저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:

저작자표시. 귀하는 원저작자를 표시하여야 합니다.

비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.

변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

석사학위 논문

세분화된 감정 인식을 위한 딥러닝 기반 텍스트 데이터 분석 연구

-감성 대화 말뭉치 데이터를 중심으로-

A study of fine-grained emotion identification via text data analysis based on deep learning

: Focused on emotional conversation corpus data

2023년 12월

숭실대학교 대학원

IT정책경영학과

이 현 주

석사학위 논문

세분화된 감정 인식을 위한 딥러닝 기반 텍스트 데이터 분석 연구

-감성 대화 말뭉치 데이터를 중심으로-

A study of fine-grained emotion identification via text data analysis based on deep learning

: Focused on emotional conversation corpus data

2023년 12월

숭실대학교 대학원

IT정책경영학과

이 현 주

석사학위 논문

세분화된 감정 인식을 위한 딥러닝 기반 텍스트 데이터 분석 연구

-감성 대화 말뭉치 데이터를 중심으로-

지도교수 김 광 용

이 논문을 석사학위 논문으로 제출함

2023년 12월

숭실대학교 일반대학원

IT정책경영학과

이 현 주

이 현 주의 석사학위 논문을 인준함

심 사 위 원 장 최 정 일 (인)

심 사 위 원 김 홍 배 (인)

심 사 위 원 김 광 용 (인)

2023년 12월

숭실대학교 대학원

목 차

국문초록 ····· iv
영문초록 ····· v

제 1 장 서론 ····· 1
1.1 연구의 배경과 목적 ····· 1
1.1.1 기계와 인간의 대화 ····· 1
1.1.2 인간 지능에 대한 본질적 탐구 ····· 1
1.1.3 인간 지능에 대한 인식 변화 ····· 2
1.1.4 기계와 인간의 상호작용 영역 확대 ····· 3
1.1.5 연구의 목적 ····· 4
1.2 연구내용 및 방법 ····· 7
1.2.1 연구내용 ····· 7
1.2.2 연구방법 ····· 7
1.3 논문의 구성 ····· 8

제 2 장 이론적 배경 및 선행연구 ····· 9
2.1 ‘감정’과 ‘감성’의 정의 탐색 ····· 9
2.1.1 ‘감정(emotion)’의 정의 ····· 9
2.1.2 ‘감성(sentiment)’의 정의 ····· 13
2.1.3 ‘감정분석’과 ‘감성분석’의 구분 ····· 14
2.2 ‘감정’과 ‘감성’분석 선행연구 ····· 15
2.2.1 감정분석 선행연구 ····· 14
2.2.2 감성분석 선행연구 ····· 18
2.2.3 감정・감성분석 병행 선행연구 ····· 20
2.3 다양한 BERT모델 비교 ····· 21

2.3.1 BERT 모델 개요 ····· 21
2.3.2 BERT 모델의 구조 ····· 22
2.3.3 다양한 BERT 파생모델 비교 ····· 24

제 3 장 실험방법 ····· 26
3.1 실험환경 및 데이터 ····· 26
3.1.1 실험환경 ····· 26
3.1.2 KoBERT모델 ····· 26
3.1.3 사전학습용 데이터 ····· 27
3.1.4 성능검증용 데이터 ····· 28
3.2 실험방법 ····· 30
3.2.1 실험 개요 ····· 30
3.2.2 학습 데이터 감정라벨 재분류 ····· 31
3.2.3 사전학습 데이터의 전처리 ····· 34
3.3 사전학습 ····· 37
3.4 모델 성능 검증 ····· 39

제 4 장 실험결과 ····· 40
4.1 사전학습 결과 ····· 40
4.2 모델 성능검증 결과 ····· 44

제 5 장 결론 ····· 45
5.1 결론 및 시사점 ····· 45
5.2 연구의 한계 및 향후 연구 발전 방향 ····· 47

참고문헌 ····· 49

표 목 차

[표 1] 사전에 표기된 '감정'의 정의 ····· 9
[표 2] 감정의 정의(Kleinginna & Kleinginna, 1981) ····· 11
[표 3] 사전에 표기된 '감성'의 정의 ····· 13
[표 4] affect, feeling, emotion, sentiment, opinion의 정의 ····· 13
[표 5] Sentiment 관련 문헌 분석 ····· 14
[표 6] 감정 및 감성분석 선행연구 분류기준 ····· 15
[표 7] 감정분석 연구 비교항목 ····· 16
[표 8] 감정분석 연구 비교 ····· 17
[표 9] 감성분석 연구 비교 ····· 19
[표 10] 감정·감성분석 병행연구 비교 ····· 20
[표 11] 모델 효율성 제고를 목적으로 개발된 BERT 파생모델 ····· 24
[표 12] 한국어 데이터를 기반으로 사전 학습시킨 BERT모델 ····· 25
[표 13] 실험환경 ····· 26
[표 14] 감성 대화 말뭉치의 감정 분류 기준 ····· 29
[표 15] D. Demszky et al.(2020)에 제시된 감정 분류체계 ····· 31
[표 16] 사전학습용 데이터 재분류 결과 ····· 32
[표 17] 성능검증용 데이터 재분류 결과 ····· 33
[표 18] 실험에 활용한 외부 라이브러리 ····· 34
[표 19] 사전학습 결과 ····· 40
[표 20] 모델의 분류와 정답 ····· 41
[표 21] 감정별 분류 성능 ····· 42
[표 22] 대화 데이터를 통한 모델 성능 검증 결과 ····· 44
[표 23] 감정별 분류 성능 ····· 44

그 림 목 차

[그림 1] (좌) 카페 ‘스토랑트’의 바리스타 로봇 (우) 영화 ‘에이아이’의 주인공 ‘써니’ ····· 3
[그림 2] (좌) ChatGPT 업무활용 예시 (우) 생성형AI로 만든 예술작품 4
[그림 3] (좌) 극한 환경 정밀탐사 수중 촬영 로봇 (우) 노인 돌봄로봇 서비스 ····· 5
[그림 4] 감정연구를 통해 도출된 감정모델 예시 ····· 6
[그림 5] 연구 수행절차 ····· 7
[그림 6] Transformer 모델의 구조(A. Vaswani et al., 2017) ····· 21
[그림 7] BERT 모델의 자연어 처리 과정(J. Delvin et al., 2019) ····· 22
[그림 8] BERT 모델의 input representation(J. Delvin et al., 2019) ····· 23
[그림 9] BERT vs GPT vs ELMo(J. Delvin et al., 2019) ····· 23
[그림 10] KoBERT모델 구조 ····· 27
[그림 11] ‘한국어 감정 정보가 포함된 단발성 대화 데이터셋’ 말뭉치 구조 ····· 28
[그림 12] 말뭉치 데이터 구조 ····· 29
[그림 13] 실험과정 ····· 30
[그림 14] 감정모델 세팅 ····· 35
[그림 15] 데이터셋 및 분류 클래스 적용 ····· 35
[그림 16] 토크나이저 적용 및 하이퍼 파라미터 조정 ····· 37
[그림 17] 하이퍼 파라미터 조정(2) ····· 37
[그림 18] 사전학습 수행 ····· 38
[그림 19] 학습모델 저장 ····· 39
[그림 20] 학습컨디션 조절 ····· 39
[그림 21] 사전학습 후 KoBERT 모델 변화 ····· 43

국문초록

세분화된 감정 인식을 위한 딥러닝 기반 텍스트 데이터 분석 연구

-감성 대화 말뭉치 데이터를 중심으로-

이현주

IT정책경영학과

숭실대학교 일반대학원

인공지능 기술, 특히 자연어 처리 모델의 발전은 인간과 기계 사이에서 실제 인간의 담화와 유사한 대화를 가능하게 하였다. 최근에는 기계와 인간 사이 상호보완이 필요한 영역이 확대되면서 인간 지능에 대한 본질적 개념을 이해하고, 인간과 기계 지능의 가장 큰 차이점인 정서적 측면에 초점을 맞춘 감성 인공지능 분야의 연구가 활발히 진행되고 있다. 하지만 감성 인공지능 분야 내 자연어 처리 연구에서 다루고 있는 인간의 감정모델 개수는 약 6 ~ 8개 정도로, 실제 인간의 다양한 감정을 이해시키기에 부족한 부분이 존재한다. 또한, 다수의 연구에서 '감정'과 '감성'의 개념이 혼재되어 있는 경우도 확인하였다. 이러한 문제점을 해결하기 위해 본 연구에서는 다양한 문헌 분석을 통해 인간의 '감정'과 '감성'의 구분을 확고히 하고, 디테일하게 분류된 다수의 감정모델 기반의 감정분석을 수행하였다. 결과적으로 기존 연구 대비 모델의 성능이나 정확도는 다소 낮게 나타났지만, 세분화된 감정 인식 연구의 발전 가능성을 확인할 수 있었다.

ABSTRACT

A study of fine-grained emotion identification via text data analysis based on deep learning

: Focused on emotional conversation corpus data

Lee, Hyunjoo

Department of IT Policy and Management

Graduate School of Soongsil University

Natural-sounding human-machine interactions have been made possible by advancements in artificial intelligence, especially in natural language processing models. With the emotional component being the primary distinction between human and machine intelligence, research on emotional AI has been particularly active in the last few years. The goal is to comprehend the basic idea of human intelligence. The expansion of the domain of human-machine complementarity is the reason behind this. The topic of emotional AI natural language processing research has sadly only examined about 6–8 human emotion models, which is insufficient to properly understand the gamut of human emotions. More than one study has found that there is a misunderstanding between the terms "sentiment" and "emotion." To address these problems, this study distinguished between human "sentiment" and "emotion" utilizing a range of literature findings and

performed emotion analysis using a number of intricately categorized emotion models. I was able to validate the idea of conducting a fine-grained emotion recognition investigation, even though we discovered that the models' performance and accuracy were somewhat lower than in earlier experiments.

제 1 장 서 론

1.1 연구의 배경과 목적

1.1.1 기계와 인간의 대화

자연어 처리모델의 발전은 실제 사람의 담화 내러티브와 유사한 기계와의 대화를 가능하게 하였다. 가장 대표적인 예로는 2023년 상반기 최고의 화두인 'ChatGPT'를 들 수 있다. 실제 사람의 대화처럼 주제가 계속 이어질 뿐만 아니라, 칭찬을 하면 감사를 표하고, 화를 내면 사과를 한다. 지적을 하면 시정하겠다고 하고, 비윤리적인 의도로 접근할 경우 사유를 대며 회피한다. 물론, 기존에도 'Max'[1]나 '심심이'[2] 같은 컴퓨터와의 대화를 시도하는 서비스가 있었지만, 최근에 등장한 대화형 서비스들과의 품질을 비교해봤을 때, 이들과의 대화를 '인간적인' 대화라고 간주하기에는 어려움이 있다. 기계와 인간의 밀접한 협업을 위해서는 기계가 인간의 정서적 측면을 이해하는 과정이 선행되어야 한다. 그렇다면 어떻게 인간의 세분화된 감정을 기계가 인식하도록 할 수 있을까?

1.1.2 인간 지능에 대한 본질적 탐구

지능(智能, intelligence)이란, 새로운 대상이나 상황에 부딪혀 그 의미를 이해하고 합리적인 적응 방법을 알아내는 지적 활동의 능력을 뜻한다.

2016년 3월 9일~15일까지 약 일주일 간 진행된 '구글 딥마인드 챌린지(Google DeepMind Challenge Match)' 당시 이세돌 九단과 구글의 알파고(AlphaGo)[3] 간 대국에서, 모든 국을 불계[4]로 알파고가 5전 3선승 하

1) Max : 93년에 개발된 컴퓨터와의 채팅 프로그램

2) 심심이 : 2002년 서비스를 시작한 대화형 챗봇 서비스

3) 알파고(AlphaGo) : 알파벳(Alphabet)의 자회사이자 영국의 인공지능 연구기업인 구글 딥마인드(Google DeepMind)에서 개발한 바둑 인공지능 프로그램

였다. 당시 이세돌과 대결했던 알파고의 기력은 이미 프로의 수준을 훨씬 상회하는 것으로 평가되었다. 기계가 외부 데이터에 의존하지 않고 자체 학습을 통해 배운다는 부분에 전 세계가 주목하며, 2010년대 초반 딥러닝(Deep-learning)을 중심으로 부흥기에 접어든 인공지능 연구가 급성장하는 계기가 되었다.

이러한 과정에서 그 동안 인류의 전유물로 여겨지던 '지능'에 대한 연구목표는 곧 '인간 지능을 닮은 기계 지능의 구현'이자, '인간의 지능 그 자체에 대한 이해'로 이어졌다(Russel & Norvig, 2015). 이는 기계의 인간과 같은 지능적 행위 가능성에 대한 탐색이면서, 다른 한편으로는 인간의 지능 혹은 이성 능력의 정체를 더 잘 이해하기 위한 노력으로 볼 수 있다(천현득, 2017). 그러한 측면에서 최근 압도적인 과제 수행능력으로 무장한 기계의 등장은 '지능'이라는 말 자체의 의미와 본질적 요소를 변화시키고 있다(천현득, 2017).

1.1.3 인간 지능에 대한 인식 변화

퀴즈쇼나 체스 게임, 바둑 등에서 인간과 경쟁하여 승리한 IBM의 '왓슨(Watson)', '딥블루(Deep Blue)', 그리고 구글 딥마인드의 알파고가 자의식이 있다고 생각하는 사람들이 있을까? 그들은 인간을 이기기 위한 목적으로 게임에 임한 것이 아니라, 주어진 과제를 효율적이고 효과적으로 수행하기 위한 방법을 학습하고 결과를 내놓았을 뿐이다. 그들은 경쟁에서 승리했지만, 이러한 행동이 무엇을 의미하는지 이해할 수 없을 뿐만 아니라, 자신이 이겼다는 사실조차 인식하지 못한다(Kaku, 2014). 사람은 결과에 따라 서로를 격려·위로하는 감정적 상호작용을 수행하고, 다음 경쟁에서 더 나은 결과를 도출하기 위해 전의를 다지고 노력한

4) 불계승(不計勝) : 대국을 하던 중 더 이상 이길 가망이 없다고 판단되어 패배를 인정하고 더 이상의 대국 진행을 포기하는 것

다. 이것이 '인간 지능'과 '기계 지능'의 본질적 차이다. 사람들은 이제 기계 지능과 차별화 된 인간성의 핵심 영역을 지적 능력보다 정서적 측면에서 찾고자 한다(천현득, 2017).

최근 '바리스타 로봇', 과 '서빙 로봇'이 음료 제조와 서빙을 대신하는 '스토랑트(Storant)'라는 브랜드가 등장하였다[5]. 이 브랜드의 '바리스타 로봇'을 영화 '에이아이(A.I.)'에 등장하는 로봇 '써니'와 비교했을 때, 사람들은 둘 중 누가 더 '인간'에 가깝다고 생각하고, 둘 중 누가 더 '지능이 높다'라고 생각할까? 그리고 그렇게 생각하게 하는 기준이나 배경은 과연 무엇일까?

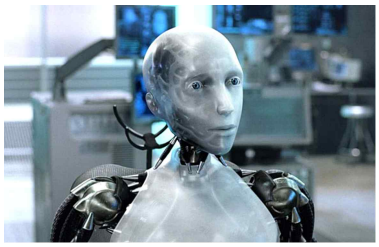

[그림 1] (좌) 카페 '스토랑트'의 바리스타 로봇 (우) 영화 '에이아이'의 주인공 '써니'

1.1.4 기계와 인간의 상호작용 영역 확대

통상적인 개념으로써 '인공지능' 발달은, 인간의 많은 직업을 기계나 로봇으로 대체할 것이라는 우려와 동시에, '창의적 문제제기 능력, 정서적 결속 능력, 총체적 판단 능력은 오랫동안 인간 특유의 영역으로 남아 있을 것' 이라는 평가(송성수, 2022)도 존재한다. 기계의 인간 노동 대체 측면은 과장하고, 인간 노동에 대한 자동화 시스템의 상호 보완적 측면은 무시한다는 지적(D. H. Autor, 2015)도 있다. 그렇다면, 이러한 인간 노동 영역에서 자동화 시스템, 기계 혹은 로봇 등과 '상호 보완'이 가장 필요한 부분은 과연 어떤 영역일까?

5) http://www.storant.co.kr

2023년 1월을 기점으로 출시 1개월 만에 1억 명 이상의 사용자를 확보한 'ChatGPT'의 등장 이후, 생성형AI 관련 기술 발달로 다양한 형태의 생성형AI 서비스가 등장하였다. 이러한 생성형AI 서비스는 인간의 창의적 활동을 보조할 뿐만 아니라 인간의 고유한 영역으로 여겨지던 문화·예술 등의 영역에서 인간과 기계의 협업을 가능하게 하였다. [그림 2]의 좌측 예시는 '스파르타코딩클럽' 이라는 교육기관에서 취업 부트캠프 홍보를 위한 보도자료를 ChatGPT에 요청하여 받은 결과물이고, 우측의 미술 작품은 '스페이스 오페라 극장'이라는 콜로라도 주립 박람회 미술대회 1등 수상작으로, 게임 디자이너인 제이슨 알렌(Jason M. Allen)이 텍스트를 입력하면 이를 그래픽 아트로 만들어주는 생성형 AI 도구 '미드저니(Midjourney)'를 활용한 결과물이다.

[그림 2] (좌) ChatGPT 업무활용 예시 (우) 생성형AI로 만든 예술작품

1.1.5 연구의 목적

전 세계적으로 초고령화 사회 진입 및 인구 급감이 사회적 이슈로 떠오르고 있으며, 한국도 2025년을 기점으로 65세 이상 고령 인구 비중이 20.6%까지 증가하며 초고령화 사회로 진입할 예정이다(통계청, 2022). 이에 따라 인간을 대체할 기계와 로봇의 수요 영역이 확대되고 있다. 일반적으로 '로봇'이 가장 활발하게 활용되는 영역은 단순노동의 대체 또는 방사능, 고온·고압의 극한 환경 속 작업 수행으로 알려졌지만, 최근에는 독거노인이나 치매노인 돌봄서비스를 제공하는 로봇의 개발도 활발하게 진행 중이다.

[그림 3] (좌) 극한 환경 정밀탐사 수중 촬영 로봇 (우) 노인 돌봄로봇 서비스

그러나 기계의 지능이 아무리 발달하고 인간을 대체할 기계와 로봇의 수요가 증가한다 해도, 기계가 사람의 정서적 측면을 제대로 이해하지 못한다면 '인간 지능'의 본질을 이해하지 못하는 것이나 다름없으며, 그러한 상황이 지속될 경우 기계의 역할은 어디까지나 단순노동 혹은 극한 환경 속 노동력의 대체 수준에 머무를 수 밖에 없을 것이다.

특히, 노인이나 어린이 등 신체적·정서적으로 취약한 대상을 지원하는 서비스의 경우 섬세하고 밀접한 정서적 교감과 애착 형성이 중요한데, 이를 위해서는 기계가 사람의 감정이나 감성을 인간과 동일한 수준으로 인식하는 과정이 필수적으로 선행되어야 한다. 이러한 측면에서, 인간과의 밀접한 상호작용을 위해 인간의 다양한 감정과 감성을 기계가 학습하고 인지하게 하는 방법론과 기술개발 연구가 활발하게 진행 중이다. 감정 및 감성분석 연구도 그 중 한 분야에 속한다.

하지만 대다수의 감정분석 연구가 Ekman, Plutchik 등이 제시한 6 ~ 8가지 감정모델 중심으로 연구되고 있어 인간의 다양한 감정을 다루지 못하고 있다는 한계에 봉착하고 있으며, 사전학습에 활용한 데이터 역시 감정적 요소가 내포된 데이터의 희소성으로 인해 감정분석을 주된 목적으로 하기에는 다소 미흡한 감이 있다.

그나마 최근에 들어서는 감정분석 연구에 Russel(1980), Cowen et al.(2019), Wang(1980) 등 20여 가지 이상의 감정을 포함한 모델을 활용하려는 움직임이 있었고, 카카오나 네이버 등 국내 인공지능 연구 선도

기업들의 경우 각 사가 보유한 방대한 데이터를 정신의학과 전문의 등 전문가를 활용하여 분류하는 작업을 수행하고 있다.

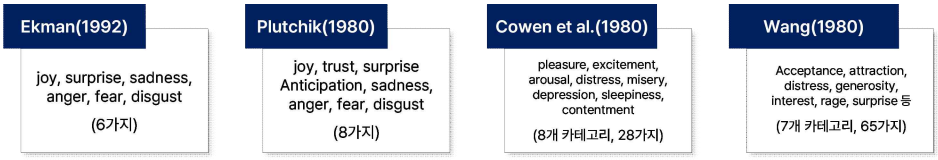

[그림 4] 감정연구를 통해 도출된 감정모델 예시

본 연구를 통해 세분화된 감정 모델을 적용하고 감정적 요소를 중점적으로 다룬 데이터를 기반으로 선행학습을 수행하여 언어모델을 개선함으로써, 기존 연구 대비 분석 가능한 감정의 범위를 확대함과 동시에 감정 분석 정확도를 제고하는 것이 연구의 주 목적이며, 궁극적으로는 본 연구의 결과를 기반으로 사람과 기계 간의 보다 '인간적인' 상호작용이 가능한 방안을 마련하고자 한다.

1.2 연구내용 및 방법

1.2.1 연구내용

본 연구는 먼저, 기존의 감정 및 감성분석 연구에서 혼재되고 있는 '감정'과 '감성'의 정의를 분명히 하고, 감정분석에 주로 사용되는 다양한 BERT모델을 비교하기 위해 국내외 다양한 문헌을 대상으로 선행연구 분석을 수행하였다.

다음으로, 기존의 6가지 감정으로 분류된 단문 중심의 선행학습용 데이터를 27가지의 감정모델을 기반으로 재분류하여 감정분류에 특화된 자연어 처리 모델에 사전학습 시키는 과정을 수행하였다.

마지막으로, 기존 풍부한 감정 요소가 내포된 17만 단어 분량의 대화형 데이터를 사전학습된 모델에 적용하여 분류 성능을 확인하였다.

1.2.2 연구방법

본 연구의 목적을 달성하기 위해 [그림 5]와 같은 프로세스로 연구를 수행하였다.

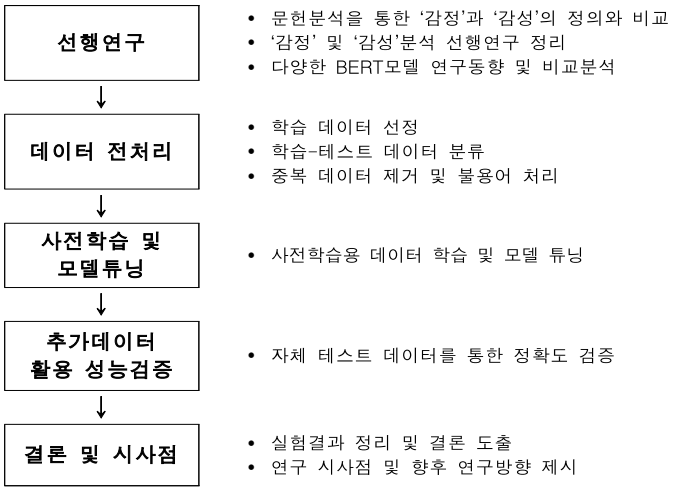

[그림 5] 연구 수행절차

1.3 논문의 구성

본 논문은 다음과 같이 총 5장으로 구성되었다.

제1장 서론에서는 연구하고자 하는 분야의 산업 및 기술적 배경을 제시하고 그에 따른 연구 목적을 밝혔으며, 전반적인 연구의 내용과 방법을 정리하였다.

제2장 이론적 배경 및 선행연구에서는 △'감정'과 '감성'의 정의를 확고히 하고 △'감정'과 '감성' 분석연구 동향을 탐색하며 △실험에 활용할다양한 BERT 알고리즘을 비교하기 위한 국내·외 문헌정보 분석 결과를 정리하였다.

제3장 실험방법에서는 실험에 활용된 데이터에 대해 소개하고, 사용한 연구모델에 대한 개요와 본격적인 데이터 학습 과정 및 학습을 통한 모델 정확도 검증 결과를 서술하였다.

제4장 실험결과에서는 제3장의 실험방법에 따른 실험 결과를 정리한다. 사전학습 모델을 기반으로 추가적인 데이터의 학습-테스트를 거친 후 정확도 검증 결과를 제시함으로써 실험의 효과를 서술하였다.

제5장 결론에서는 실험결과를 통한 최종 결론 및 실험결과가 시사하는 바를 정리하여 실험을 통한 기대효과를 제시하는 한편, 실험 과정에서 아쉬웠던 점이나 한계를 기반으로 향후 연구에 반영하고자 하는 내용들을 서술하였다.

제 2 장 이론적 배경 및 선행연구

2.1 ‘감정’과 ‘감성’의 정의 탐색

감정 및 감성분석을 수행한 선행연구 탐색 과정에서, 국내뿐만 아니라 국외의 다수 논문에서 ‘감정’과 ‘감성(정확한 한국어 어휘로는 ‘감상’)’의 개념이 혼재되고 있음을 확인하였다. 감정과 감성(혹은 감상, 정서)은 종종 대체 가능한 개념으로 간주되지만, 일반적으로 ‘감정’은 특정 상황이나 사건에 대한 사람들의 느낌 혹은 반응으로, ‘행복’, ‘슬픔’, ‘분노’ 등이 그 몇 가지 예이며, 감성은 그러한 감정들을 긍정 혹은 부정으로 일반화하는 것이라 할 수 있다(M. Munezero et al., 2014). 본 연구를 통해 수행한 감정 및 감성분석 결과를 정확하게 분류하여 제시하기 위해 먼저 감정과 감성의 정의를 정리하였다.

2.1.1 ‘감정(emotion)’의 정의

각 국가의 사전을 통해 ‘감정’의 정의를 탐색한 결과는 [표 1]과 같다.

[표 1] 사전에 표기된 ‘감정’의 정의

사전명	정의	비고
국립국어원 ‘한국어기초사전’	일이나 대상에 대하여 마음에 일어나는 느낌이나 기분	감정[1](感情) 기준
OED(Oxford English Dictionary)	A strong feeling deriving from one’s circumstances, mood, or relationships with others	Emotion 기준
APA Dictionary of Psychology	A complex reaction pattern, involving experiential, behavioral, and physiological elements, by which an individual attempts to deal with a personally significant matter or event	Emotion 기준

국립국어원의 ‘한국어기초사전’에서 ‘감정[1](感情)’은 ‘일이나 대상에 대하여 마음에 일어나는 느낌이나 기분’으로, 옥스퍼드 사전에서는

‘Emotion’을 ‘자신의 상황 기분 또는 다른 사람과의 관계에서 비롯되는 강한 느낌’으로 정의했다. 심리학 용어 사전인 APA Dictionary of Psychology에서는 감정을 ‘개인적으로 중요하다고 인식되는 상황에 대한 반응으로 나타나는 생리적 각성, 감정, 인지 과정 및 행동 반응을 포함한 복잡한 변화 패턴’으로 설명하고 있다.

위와 같이 사전에 명시된 ‘감정’의 정의는 다소 추상적이며, 유사하게 사용되는 ‘감성’이나 ‘정서’ 등의 개념들과 명확하게 구분되지 않는 경향이 존재한다. 그렇다면 이전의 감정 연구자들은 ‘감정’을 어떻게 정의하고 있을까?

P.R. Kleinginna & A.M Kleinginna(1981)에서는 1970년 이전과 이후에 발간된 심리학 문헌 총 101건을 분석하여 총 92개의 감정에 대한 정의 및 9개의 회의적 의견을 수집하였다. 해당 의견들을 감정 발생 현상이나 감정 이론에서 다루는 쟁점을 기준으로 하여 총 11개 범주로 분류하였다. 범주에 따라 보조적 의견 등의 차이가 존재하지만 공통적으로 아래와 같은 정의와 특성을 가진다.

- *감정은 신경 호르몬 체계를 매개로 하는 주관적·객관적 요인 간의 복잡한 상호작용*
  - *흥분, 쾌감/불쾌감과 같은 정서적 경험 유발*
  - *감정과 관련된 지각 효과, 평가, 분류 등과 같은 인지적 과정 생성*
  - *흥분 상태 시의 광범위한 생리적 조절 활성화*
  - *(일반적이지는 않지만) 대부분 표현을 중시하고 목표 지향적이며 적응 행동으로 이어질 수 있는 복잡한 상호작용의 집합*

문헌에 정리된 감정의 정의 및 의견은 [표 2]와 같다.[6)]

6) Kleinginna & Kleinginna(1981) Appendix 일부만 발췌

[표 2] 감정의 정의(Kleinginna & Kleinginna, 1981)

범주	정의 & 의견	문헌명
Affective Definitions	"The bodily changes follow directly the perception of the exciting fact, and that our feeling of the same changes as they occur is the emotion"	W. James(1884)
Cognitive definitions	"Emotions are phases of an individual's intuitive appraisals either of his own organismic states and urges to act or of the succession of environmental situations in which he finds himself."	J. Bownby(1969)
External Stimuli Definitions	"The characteristics of emotion may be summarized in the following way: 1. Emotions are generally aroused by external stimuli. 2. Emotional expression is typically directed toward the particular stimulus in the environment by which it has been aroused. 3. Emotions may be, but are not necessarily or usually, activated by a physiological state. 4. There are no 'natural' objects in the environment (like food or water) toward which emotional expression is directed. 5. An emotional state is induced after an object is seen or evaluated, and not before."	R. Plutchik(1980)
Physiological Definitions	"For the theory that emotional experiences arise from changes in effector organs is substituted the idea that they are produced by unusual and powerful influences emerging from the region of the thalamus and affecting various systems of cortical neurones"	W. B. Cannon(1928)
Emotional~ Expressive Behavior Definitions	"A class of qualities which is inherently linked to the motor system, so that its uniqueness is complete only with inclusion of the dynamics of the motor system as an integral part of their spatio-temporal existence .... Emotion and its expression form an existential unit, a system"	M. Clynes(1977)

범주	정의 & 의견	문헌명
Disruptive Definitions	“In the disruptive state called emotional the victim can be said, in one sense, 'not to know what to do' .... Accompanying this disruptive condition we have those strange visceral and vegetative phenomena commonly recognized as characteristic of the emotional condition”	D. T. Howard(1928)
Adaptive Definitions	“An emotion may thus be provisionally defined as a somatic readjustment which is instinctively aroused by a stimulating situation and which in turn promotes a more effective adaptive response to that situation”	H. A. Carr(1929)
Multiaspect Definitions	"Emotion is a complex concept with neurophysiological, neuromuscular, and phenomenological aspects. At the neurophysiological level emotion is defined primarily in terms of patterns of electrochemical activity in the nervous system .... At the neuromuscular level emotion is primarily facial activity and facial patterning, and secondarily it is bodily (postural-gestural, visceral, and sometimes vocal) response. At the phenomenological level emotion is essentially motivating experience and/or experience which has immediate meaning and significance for the person.“	C. E. Izard(1971)
Restrictive Definitions	“Ideas are cathexes-ultimately of memory traces-while affects and emotions correspond to processes of discharge, the final expression of which is perceived as feeling”	S. Freud(1915)
Skeptical Statement	“I can therefore see no reason for a psychological study of 'emotion' as such. Emotion has no distinguishing characteristics. It represents merely an extreme manifestation of characteristics found in some degree in all responses”	E. Duffy(1941)

2.1.2 '감성(sentiment)'의 정의

감정의 정의 도출 과정과 마찬가지로, 각 국가별 사전에 명시된 '감성'의 정의는 [표 3]과 같다.

[표 3] 사전에 표기된 '감성'의 정의

사전명	정의	비고
국립국어원 '한국어기초사전'	자극에 대해 마음이나 감각이 느끼고 반응하는 성질	감성(感性) 기준
OED(Oxford English Dictionary)	A feeling or an opinion, especially one based on emotions	Sentiment 기준

우리말 사전에서는 '감성'과 '감정' 간 정의에서 크게 다른 점이 드러나지 않지만, 옥스퍼드 사전의 경우 '감정'은 (상황이나 관계에 따라 다양하게 분류되는) '느낌'으로, '감성'은 '의견'으로 정의하는 명확한 차이가 존재한다.

그렇다면 연구자들은 '감성'을 어떻게 정의했을까? M. Munezero et al. (2014)는 affect, feeling, emotion, sentiment, opinion의 5가지 개념을 주제로 용어정의 및 각 개념 간 차별화 요소를 도출하기 위해 다수의 심리학 문헌들을 분석하여 비교하였다. 비교를 통한 각 개념의 정의는 [표 4]와 같다.

[표 4] affect, feeling, emotion, sentiment, opinion의 정의

용어	정의
Affect	무의식적인 영향으로, 언어적 개념화가 어렵기 때문에 텍스트에서 감지 불가
Feeling	분류화 된 의식적 현상으로, 텍스트에서 감지 가능
Emotion	복집한 심리적 현상으로, 이를 구성하는 다섯가지 요소(평가, 감정, 생리적 반응, 표현적 행동, 특정 방식으로 행동할 준비)에 대해 글로 표현한 경험
Sentiment	특정 대상에 일정 기간 동안 지속적으로 형성된 감정적 성향으로, 의사결정을 개선하는데 도움을 줌
Opinion	정보에 대한 개인적인 해석으로, 감정이나 정서와 연결될 수도, 그렇지 않을 수도 있음

[표 4]와 같은 결론을 도출하기 위해 M. Munezero et al.(2014)에서 분석한 감성 관련 문헌과 문헌에서 제시한 정의는 [표 5]와 같다.

[표 5] Sentiment 관련 문헌 분석

문헌명	정의
R. Cattell(2006)	An acquired and relatively permanent major neuropsychic disposition to react emotionally, cognitively, and conatively toward a certain object (or situation) in a certain stable fashion, with awareness of the object and the manner of reacting
S. L. Gordon(1981)	Socially constructed patterns of sensations, expressive gestures, and cultural meanings organized around a relationship to a social object, usually another person (.. .) or group such as a family
H. Murray & C. Morgan(1945)	A more or less enduring disposition (predilection or readiness) in a personality to respond with a positive or negative affect to a specified entity
C. D. Broad(1971)	A sentiment is formed when a certain object is constantly perceived or thought of by a person and, over time, the person creates a dispositional idea toward the object

2.1.3 '감정분석'과 '감성분석'의 구분

2.1.1 및 2.1.2에서 제시한 '감정'과 '감성'의 개념을 기반으로 '감정분석'과 '감성분석'을 구분하면 다음과 같다. 감성분석은 텍스트, 오디오, 혹은 비디오 등에서 '긍정' 혹은 '부정'의 감성 극성을 감지하는 것을 목표로 하는 연구이고, 오피니언 마이닝(Opinion mining)이라고 불리기도 한다. 감정분석은 그러한 감성 극성 내에서 표현될 수 있는 더 정확한 감정을 분석하는 연구이다. 두 분야는 완전히 분리되어 연구되는 경우도 있지만 감정을 먼저 분석하고 이를 감성 극성에 따라 긍·부정으로 분류하거나, 긍정/부정 반응을 도출한 후 이를 세분화하여 상세한 감정으로 분류하는 등 다양한 방식으로 연구된다.

2.2 ‘감정’과 ‘감성’ 분석 선행연구

본 논문에서는 앞서 2.1을 통해 ‘감정’과 ‘감성’의 명확한 정의를 수립하고, 그에 따른 ‘감정분석’과 ‘감성분석’의 분류기준을 정립하였다. 이에 따라 감정분석 및 감성분석 선행연구를 분석하고 그 결과를 [표 6]의 기준을 바탕으로 세 가지 유형으로 나누어 정리하였다.

[표 6] 감정 및 감성분석 선행연구 분류기준

분류	정의
감정분석만 수행	Ekman, Plutchik 혹은 추가적인 연구를 통해 제시된 감정 모델을 기반으로 비정형 데이터 분석 수행
감성분석만 수행	긍정(Positive)/부정(Negative)의 양극화 된 정서(혹은 중립 포함)로 비정형 데이터 분석 수행
감정/감성분석 병행	감정 및 감성분석을 병행

2.2.1 감정분석 선행연구

감정 분류 방법은 크게 사전 기반 접근법(Lexicon-based Approach)와 머신러닝 기반 접근법(Machine Learning Approach) 두 가지로 구분할 수 있다(윤경섭 & 오종민, 2022).

사전기반 접근법은 학습 기반이 되는 어휘사전 등을 활용하는 방식으로, 매뉴얼, 감정(감성)사전, 말뭉치 기반 접근법 등이 존재한다. 머신러닝 기반 접근법은 인공신경망을 활용한 딥러닝 기법으로, 대표적으로 Google에서 2018년 공개한 Transfomer 기반으로 Self-Attention 기법을 활용한 BERT 모델 등이 있다. 이러한 모델들은 사전 학습된 언어모델을 도메인이나 과제에 따라 파인 튜닝(Fine-tuning)함으로써 정확도와 분류 성능을 제고할 수 있다.

최근 텍스트 데이터 등 비정형 데이터의 감정·감성분석 연구 및 연구결과들을 조사한 논문이 다수 발표되고 있다. 본 연구는 P. Nandwani &

R. Verma(2021) 및 N. Alswaidan & M. menai(2020)의 접근법을 참고하여 머신러닝 기반 접근법을 채택한 국내외 감정분석 문헌을 데이터셋, 감정모델, 사용된 감정 및 개수, 피쳐 추출 및 벡터화 기법, 학습 알고리즘, 모델 성능 등의 항목을 기반으로 비교작업을 수행하였다. 각 항목의 정의는 [표 7]과 같다.

[표 7] 감정분석 연구 비교항목

분류항목	정의
데이터셋	감정 혹은 감성 분석에 활용된 말뭉치(데이터셋)명
감정모델	분석 기준으로 활용한 감정모델명, 혹은 레퍼런스명
사용된 감정 및 갯수	감정모델에 포함된 감정 및 감정 갯수
피쳐 추출 및 벡터화 기법	전처리 된 텍스트에서 피처를 추출하고 벡터 값을 할당하는 기법
학습 알고리즘	데이터 학습 및 예측, 평가를 위한 모델
모델 성능	분석 결과 및 정확도 등을 통한 모델 성능 평가(최적 모델 중심)

분석 대상 문헌은 최근 5개년(2018 ~ 2023) 간 출간된 머신러닝 기반 접근법 채택 문헌이며, 머신러닝 기반 학습모델을 활용하지 않은 문헌은 분석 대상에서 제외하였다.

BERT모델 등장 전에는 CNN, RNN 등 인공신경망을 활용한 모델이 주를 이루었으나, 그 이후로는 기존 신경망 모델과 BERT기반 모델을 비교하여 성능을 측정하거나, BERT 모델 튜닝을 통해 모델 자체의 성능을 제고하거나 기존에 튜닝된 모델을 활용하는 등의 움직임을 보이고 있다.

또한, 감정모델의 경우 대부분 Ekman(1992)와 Plutchik(1980) 두 가지를 가장 많이 채택하였는데, 이는 해당 모델이 다양한 국가 혹은 문화권 차이에 구애받지 않는 보편적 감정(Basic-emotion)을 다루고 있기 때문인 것으로 판단된다.

[표 8] 감정분석 연구 비교

참고 문헌	데이터셋	감정 모델	사용된 감정	피쳐	학습모델	모델 성능
신동원 외(2016)	• 한국어 뉴스 기사 • 해외 드라마 자막 한국어 번역	Plutchick (1980)	기쁨, 놀람, 화남, 두려움, 슬픔, 싫어함, 바람, 미안함, 부러움, 신뢰, 무감정(8+2)	Word2 Vec	• CNN • RNN • CNN-LSTM	• CNN-LSTM 정확도 82.93%
장연지 외(2022)	• Naver Sentiment Movie Corpus	S. Soh(2012)	기쁨, 슬픔, 공포, 분노, 혐오, 놀람, 흥미, 지루함, 통증(9)	-	• KcBERT-Base • KcBERT-Large	• KcBERT-Base 정확도 91.56% • KcBERT-Large 정확도 91.42%
김재훈 외(2022)	• 주요 온라인 커뮤니티 collected	-	슬픔, 중립, 놀람, 행복, 혐오, 공포(5)	n-gram	• KoBERT	• KoBERT 정확도 70%
한재호 외(2018)	• 인터넷 뉴스댓글	Ekman(1992)	기쁨, 슬픔, 분노, 혐오(4)	Word2 Vec	• LSTM • MLP • CNN	• CNN 정확도 78.85%
T. Tang(2020)	• NLPCC 2018	-	기쁨, 슬픔, 공포, 분노, 놀람(5)	-	• RCNN • CNN • BCEL • BERT • BERT-MSAUC	-
M. Lim(2023)	• 한국어 감정 정보가 포함된 단일 대화 데이터셋 외	Plutchick (1980)	중립, 놀람, 분노, 슬픔, 기쁨, 싫어함, 공포(6)	-	• LSTM • CNN-LSTM • Transformer • IER	• IER Macro-F1 70.1%, Micro-F1 74.8%
A. Chatterjee(2018)	• Twitter Q-A pairs	Plutchik(1986)	기쁨, 슬픔, 분노(3)	Word2 Vec FastText GloVe	• NB • SVM • GBDT • CNN-NAVA • CNN-SSWE • CNN-GloVE • LSTM-SSWE • LSTM-Glove • SS-BED	• SS-BED Macro-F1 71.34, Micro-F1 71.40
M. A. Tocoglu(2019)	• Twitter collected	Ekman(1992)	공포, 기쁨, 혐오, 분노, 슬픔, 놀람(6)	NLTK	• S-CNN • CNN • S-LSTM • LSTM • S-ANN • ANN	-

2.2.2 감성분석 선행연구

감성분석은 오피니언 마이닝(Opinion mining)이라고도 하며, 제품, 서비스, 조직, 개인, 이슈, 이벤트 등의 주제에 대한 이용자의 의견, 정서, 평가, 태도, 감정 및 그 속성을 연구하는 분야이다. '의견'의 의미 자체는 매우 광범위하지만, 대부분의 감성 분석이나 오피니언 마이닝은 주로 긍정적/부정적 정서를 표현하거나 암시하는 데 초점을 맞추고 있다.(B. Liu, 2012)

감성분석 연구는 대부분 속성기반 감성분석(ABSA, Aspect-Based Sentiment Analysis), 즉 대상이 보유한 속성에 대한 감성을 분류하는 것으로, 마케팅 및 비즈니스 분야에서 가치있는 데이터를 제공하기에 다양한 산업분야에서 활용되고 있다. 속성기반 감성분석을 수행하기 위해서는 데이터에 포함된 속성어(Aspect terms)나 속성카테고리(Aspect category)를 규명해야 한다. 이러한 특성에 기반하여 속성기반 감성분석에는 속성어 추출(Aspect term extraction), 속성카테고리 감지(Aspect category detection), 속성어 감성분류(ATSC, Aspect Term Sentiment Classification), 속성 카테고리 감성분류(ACSC, Aspect Category Sentiment Classification)의 네 가지 주요 영역이 존재한다(박현정 & 신경식, 2020).

딥러닝 기반 감성분석 연구 분석은 감정분석과 달리 감정모델을 별도로 지정하지 않는 대신, 속성 분류를 위한 데이터 처리 및 데이터에 적합한 언어모델 튜닝에 중점을 두고 있어, 감정분석 연구의 분류기준이었던 감정모델 항목을 제외하였다.

감성분석 연구의 경우 2018년 BERT 등장 이후에도 기존의 인공신경망 기반 딥러닝 모델을 활용하여 분류하는 경우가 다수였으며, 이는 데이터들의 속성 간 상관정도를 고려한 모델 구현에 집중하였기 때문인 것으로 판단된다.

[표 9] 감성분석 연구 비교

문헌명	데이터셋	분류	피쳐	학습모델	모델성능
현지원 외(2022)	• 기업관련 신문기사	긍정, 부정, 중립	-	• KoBERT • MBERT	• KoBERT 정확도 85.7%
이상아 & 신효필(2021)	• 네이버 영화평 분류 코퍼스 • 공개된 악플 탐지 데이터셋	-	-	• MBERT • KorBERT • KR-BERT • KR-BERT-MEDIUM • KR-BERT-KOSAC	-
김명숙 & 김지연(2023)	• 네이버 지식iN	긍정, 부정, 중립	-	• RNN	-
박호연 & 김경재(2019)	• IMDB 영화 리뷰 데이터	긍정, 부정	BoW TF-IDF	• NB(Naive Bayes) • SVM • RF(Random Forest) • GB(Gradient Boost) • XG Boost • CNN • LSTM • CNN-LSTM	• CNN-LSTM 정확도 90.33%
R. Behera et al. (2020)	• Movie review • Airline review • US presidential election review • Self-driving car review	긍정, 부정	-	• SVM • NB • LR(Logistic Regression) • RF • CNN • RNN • Co-LSTM	• 모든 데이터셋에서 Co-LSTM 분류 정확도가 가장 우수
G. Xu et al.(2019)	• Ctrip(중국 여행 후기 사이트) collected	긍정, 부정	Seninfo +TF-IDF Word2Vec Seninfo TF-IDF	• BiLSTM • RNN • CNN • LSTM • NB	• BiLSTM F1-score 92.18
P. Jain et al. (2021)	• Airlinequality Airline Sentiment Data(항공편 리뷰 데이터셋)	긍정, 부정	-	• LR • NB • DT(Desicion Tree) • SVM • CNN • LSTM • CNN-LSTM	• CNN-LSTM 정확도 91.3%

2.2.3 감정·감성분석 병행 선행연구

BERT모델 등장 이후, 감정분석과 감성분석을 구분지어 연구하기보다, 감정 분석결과에 기반하여 각 감정을 긍정/부정 극성으로 분류하거나 감정분석과 동시에 데이터의 암묵적 속성을 기반으로 하여 감성분석을 병행하는 방식의 연구도 수행되고 있다.

[표 10] 감정·감성분석 병행연구 비교

문헌명	데이터셋	감정 모델	사용된 감정	피쳐	학습모델	모델성능
김경훈 외(2021)	• CMU-MOSEI(유튜브 영화 리뷰)	Ekman(1992)	기쁨, 슬픔, 분노, 놀람, 혐오, 공포(6) + 긍정, 부정	-	• EF-LSTM • LF-LSTM • Graph-MFN • RAVEN • MCTN • MulT • Self-MM • Multilogue-net • SMERT	• SMERT(제안모델) F1-score 84.0
윤경섭 & 오종민(2022)	• 국내 인기 음원 400곡 가사	Ekman(1992)	사랑, 즐거움, 열정, 행복, 슬픔, 분노, 외로움, 그리움, 두려움(9) + 긍정, 부정	-	• KoBERT	-

2.3 다양한 BERT모델 비교

2.3.1 BERT 모델 개요

BERT 모델은 2018년 Google에서 제안한 언어 학습모델로, 대용량의 데이터를 사전 학습시켜 이를 기반으로 사용자가 데이터 분류, 번역, 질의응답 등 사용자가 필요한 작업을 수행하기 위한 신경망을 추가하는 일종의 전이 학습 알고리즘이다(J. Delvin et al., 2019).

BERT 모델은 MLM(Masked Language Model) 및 NSP(Next Sentence Prediction)을 통해 양방향으로 문맥을 계산하는데, 이를 위해 Self-Attention 기법의 Transformer 모델을 기반으로 구성되었으며, Transformer의 인코더-디코더 중 인코더만 활용하는 방식이다.

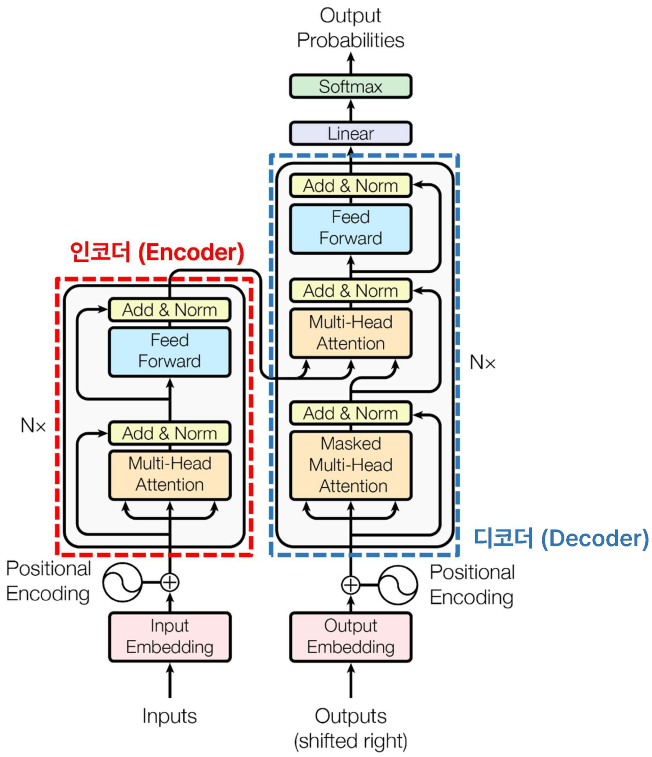

[그림 6] Transformer 모델의 구조(A. Vaswani et al., 2017)

기존 방식으로는 대용량 데이터 학습을 위해 다수의 리소스와 시간이 요구되었지만, BERT 모델은 라벨링 되지 않은 데이터를 기반으로 사전 학습된 형태이기 때문에 기존 대비 상대적으로 적은 자원으로 효율적인 자연어 처리 프로세스를 수행 가능하다.

최근에는 BERT 등 대규모 언어 모델에 특정 언어 현상과 연관이 있는 언어지식을 추가적 자질로 사용할 경우, 이와 관련된 자연어 처리 문제에서 모델 성능이 향상된다는 연구결과가 발표되며 BERT 모델에 다양한 외적 자질을 추가하는 방법론에 대한 연구가 활발히 진행 중이다(이상아 & 신효필, 2021).

2.3.2 BERT 모델의 구조

BERT 모델의 자연어 처리는 [그림 7]과 같이 인코더가 입력된 텍스트 데이터를 임베딩하여 언어 모델링을 수행하는 사전학습(Pre-training) 과정과, 이를 목적에 맞게 파인 튜닝(Fine-tuning)하여 자연어 처리 task를 수행하는 2단계로 수행된다.

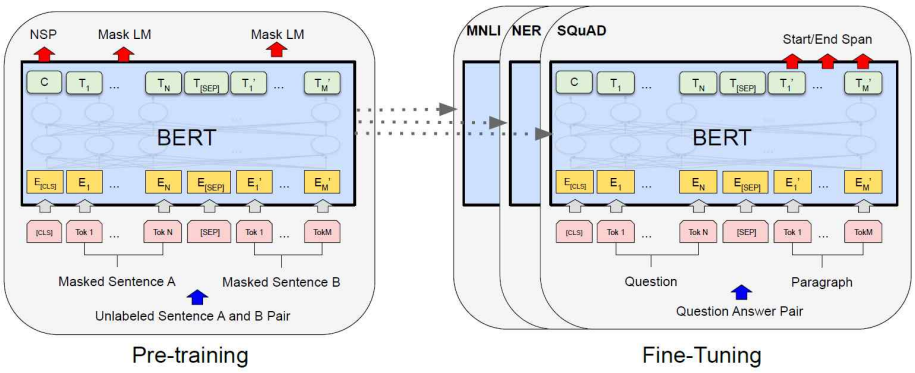

[그림 7] BERT 모델의 자연어 처리 과정(J. Delvin et al., 2019)

BERT 모델의 input representation은 [그림 8]과 같이 Token Embeddings, Segment Embeddings, Position Embeddings의 세 가지 임베딩의 합으로 구성된다. Token Embeddings는 등장 빈도가 높고 긴

sub-word를 하나의 단위로 만드는 역할로, 기존 방법론에서 빈도가 높은 단어를 전부 OOV(Out-of-vocabulary) 처리하며 발생하는 모델 성능 저하를 해결한다. Segment Embeddings는 토큰으로 나누어진 단어를 다시 하나의 문장으로 만들고, 첫 [SEP] 토큰까지의 범위를 0으로, 이후의 [SEP] 토큰까지의 범위를 1로 마스크를 생성함으로써 각 문장을 구분한다. Position Embeddings는 Self-Attention를 사용하기 위해 입력 토큰 위치 정보를 부여하여 토큰의 순서를 인코딩하는 역할이다. 모든 임베딩들의 토큰을 토큰 별로 합산하여 BERT 모델의 입력 벡터로 활용한다.

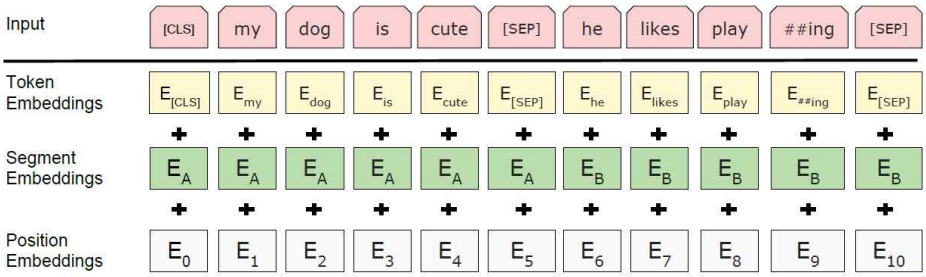

[그림 8] BERT 모델의 input representation(J. Delvin et al., 2019)

BERT와 같은 사전 학습 방식의 자연어 처리 모델인 OpenAI의 GPT, ELMo의 경우 좌-우, 혹은 우-좌 등 단방향으로 문맥을 계산하여 접합하는 형태로, 양방향으로 문맥을 계산하는 BERT 대비 상대적으로 언어 표현이 제한적이라는 단점이 존재한다. BERT는 사전학습을 위해 MLM 및 NSP를 사용하여 양방향으로 문맥을 계산함으로써 풍부한 언어표현이 가능하다.

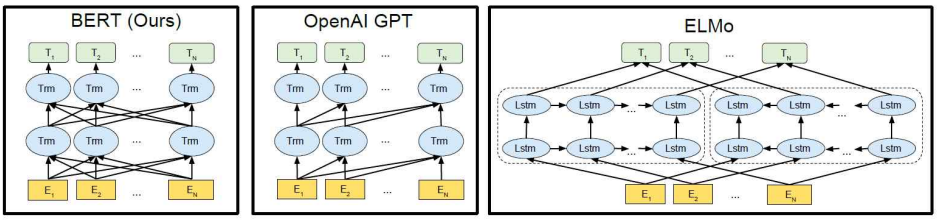

[그림 9] BERT vs GPT vs ELMo(J. Delvin et al., 2019)

2.3.3 다양한 BERT 파생모델 비교

BERT 모델은 우수한 모델이지만, 모델 사이즈가 거대하고 사용하는 자원도 많아 비효율적이며, 영문 데이터 위주의 학습모델이라는 점 등의 문제점이 존재한다. 이러한 문제점을 개선하고 보다 효율적으로 BERT 모델을 활용하기 위해 다양한 파생모델이 개발되었다.

BERT 모델의 효율성 제고를 목적으로 개발된 파생모델로는 ELECTRA, RoBERTa, DistllBERT, ALBERT, Reformer, BigBird 등이 존재한다. 각 모델에 대한 설명은 [표 11]과 같다.

[표 11] 모델 효율성 제고를 목적으로 개발된 BERT 파생모델

모델명	설명	참고문헌
ELECTRA	• 구글&스탠포드에서 2020년 발표한 모델로, 기존 MLM 방식 대신 RTD(Replaced Token Detection) 방식을 사용하여 학습 시간 단축 및 학습 효율 향상되며 동일한 모델 크기, 데이터, 컴퓨팅 리소스 조건에서 기존 BERT의 성능을 능가함	K. Clark et al. (2020)
RoBERTa	• Facebook AI에서 2019년 제안한 모델로, MLM을 통한 모델 학습 과정에 Static이나 Dynamic 방식을 활용한 마스킹 전략을 적용하고, NSP 없이 통문장(Full Sentence) 방식으로 학습시킴	Y. Liu et al. (2019)
DistilBERT	• 2019년 Hugging Face에서 발표한 모델이며 기존 BERT의 가장 큰 문제점 중 하나로 지목된 거대 파라미터 문제를 개선하기 위해 Knowledge distillation을 활용함	V. Sanh et al. (2019)
ALBERT	• 구글&도요타 공업대학(TTIC)에서 2019년 발표한 모델로, Factorized Embedding Parameterization를 통해 임베딩 레이어를 생성함으로써 임베딩 사이즈와 은닉층 사이즈를 조절하고, Cross-layer를 통해 임베딩 레이어의 구조를 전환하여 파라미터 감소	Z. Lan et al. (2019)
Reformer	• Self-attention의 비효율적인 자원 활용 문제를 해결하기 위해 2020년 구글에서 제안한 모델로, LSH Attention 등을 사용해 데이터 토큰 길이로 인한 복잡도 증가를 개선하여 성능 유지 및 효율적인 자원 활용을 도모함	N. Kitaev et al. (2019)
BigBird	• 구글IDE에서 Long-sequence 처리 문제를 해결하기 위해 개발한 모델로, self-attention layer에서 full-attention이 아닌 sparse attention 연산을 통해 Random graph 방식으로 확장하며 기존 모델 대비 8배 길이의 4096 token의 sequence input을 처리 가능하게 함	M. Zaheer et al. (2020)

BERT 모델을 감정분석에 활용할 목적으로 파인튜닝 및 데이터 사전 학습을 수행한 파생모델들도 다수 존재하는데, 그 중에서도 한국어 데이

터를 기반으로 학습된 모델로는 KorBERT, KoBERT, HanBERT, KoreALBERT, KRBERT, KcBERT 등이 존재한다. 각 모델에 대한 설명은 [표 12]와 같다.

[표 12] 한국어 데이터를 기반으로 사전 학습시킨 BERT모델

모델명	설명	참고문헌
KorBERT	• 한국전자통신연구원(ETRI)에서 2019년 공개한 최초의 한국어 사전학습 모델로, 약 15년 분량의 뉴스 및 백과사전 데이터로 사전학습을 수행했으며, 형태소 단위모델, 워드피스 단위모델, 라지 모델로 구성됨	임준호 외(2020)
KoBERT	• BERT-base-multilingual-cased의 한국어 성능 한계를 보완하기 위해 SKBrain 연구소에서 개발하였으며, 위키피디아, 뉴스 등 5천만 개 문장으로 사전학습, 불규칙한 한국어 언어 변화 특성을 반영한 데이터 기반 토큰화 기법 적용	https://github.com/SKTBrain/KoBERT
KoreALBERT	• 삼성SDS에서 2021년 개발한 모델로, 한국어 위키피디아, 나무위키, 뉴스, 책 줄거리 등의 데이터를 학습시켰고, ALBERT와 동일하게 MLM과 Sentence-order Prediction기법 적용	H. Lee et al. (2021)
KR-BERT	• BERT 모델의 과도한 크기와 비영어권 downstream task 성능 저하를 보완하기 위해 서울대에서 2020년 개발한 모델로, 한국어의 문법적 특성을 반영한 Bidirectional WordPiece Tokenizer를 적용하였고 작은 규모의 에포크에서도 우수한 성능 도출	S. Lee et al.(2020)
KcBERT KcELECTRA	• 기존의 BERT 기반 한국어 언어모델들이 정제된 데이터를 기반으로 사전학습시켜 구어체, 신조어, 줄임말, 오탈자 등이 반영되지 않은 점을 개선하기 위해 개인이 네이버 뉴스 댓글 등을 수집하여 토크나이저 및 모델을 재학습 시킨 모델	이준범(2020) https://github.com/Beomi
KoELECTRA KoBigBird DistillKoBERT	• ELECTRA, BigBird, DistilBERT 등의 파생모델에 위키피디아, 나무위키, 뉴스, 모두의 말뭉치 등 다양한 한국어 데이터를 학습시킨 모델	https://github.com/monologg

제 3 장 실험방법

3.1 실험환경 및 데이터

3.1.1 실험환경

본 연구를 위한 실험환경은 [표 13]과 같다. 실험환경은 보유하고 있는 Windows 및 macOS 기반 하드웨어 2종에서 Google Colab을 활용하였으며, 런타임 유형은 T4 GPU 환경을 기반으로 하였다.

[표 13] 실험환경

대분류	소분류	내용
하드웨어1	프로세서	• AMD Ryzen 5 5500U, 2100Mhz, 6 core
	주메모리	• 16G
	OS	• Microsoft Windows 11 Pro
	개발언어	• Python
하드웨어2	프로세서	• Apple M2 Pro
	주메모리	• 16GB
	OS	• macOS Senoma
	개발언어	• Python
소프트웨어	• Google Colab(T4 GPU)	
라이브러리	• Torch • Transfomers • Gluonnlp • Mxnet • Pandas • Tqdm • Numpy	

3.1.2 KoBERT모델

KoBERT모델은 기존 BERT모델의 한국어 처리 성능을 제고하기 위해 SKTbrain에서 개발한 모델로, 한국어 위키사전 약 5백만 문장과 한국어 뉴스 약 2천만 문장 가량을 사전학습시킨 모델이다. 사용자의 목적에 따라 파인튜닝이 가능하기 때문에 추가 레이어만으로 용도에 맞게 활용할

수 있다. 한국어 특유의 불규칙한 언어 변화 특성을 반영하고자 데이터 기반 토큰화 기법을 적용하여 기존 대비 적은 양의 토큰만으로도 성능이 향상되었다.

또한, 대용량 데이터를 단시간 내 학습하기 위해 링 리듀스(Ring-reduce) 기반 분산 학습을 수행하며, 파이토치(Pytorch), 텐서플로우(TensorFlow) 등 다양한 딥러닝 프레임워크를 지원하여 사용자 접근성이 용이하다.

BERT모델의 구조는 [그림 10]과 같으며, 기본적으로 BERT모델과 유사한 구조를 지니고 있다.

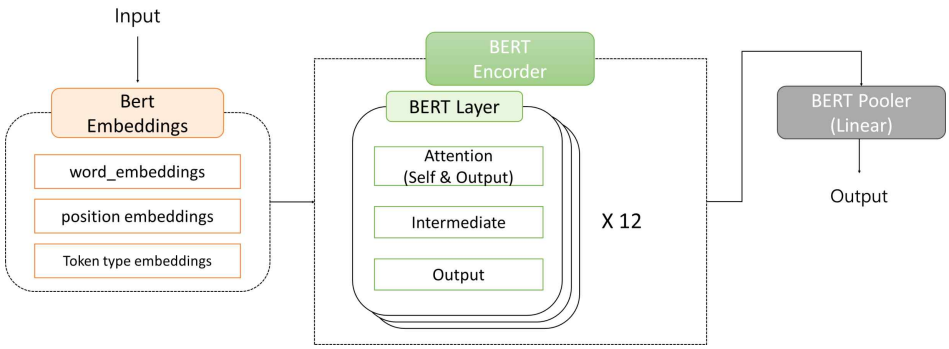

[그림 10] KoBERT모델 구조

3.1.3 사전학습용 데이터

대부분의 한국어 학습모델들은 모델 개발 과정에서 위키피디아나 뉴스, 댓글 등을 기반으로 사전학습을 시킨 형태이지만, 감정 속성이 포함되지 않은 텍스트 자체만으로 훈련시킨 경우가 대부분이다. 이를 보완하기 위해 성능검증을 위한 데이터 대비 상대적으로 가벼운 데이터인 AIhub의 '한국어 감정 정보가 포함된 단발성 대화 데이터셋'을 사전학습용 데이터로 선정하여 감정 분류 및 사전훈련을 수행하였다.

'한국어 감정 정보가 포함된 단발성 대화 데이터셋'은 소셜네트워크서비스(SNS)에 업로드 된 글 및 온라인 댓글을 대상으로 웹 크롤링을 실

시하여 대상 문장을 수집하고, 문장 단위 작업을 수행할 수 있도록 문장 분리 작업을 거친 말뭉치이다.

말뭉치는 총 38,594개 문장이며, 각 문장 당 글자수는 23.7(±13.6)글자 수집된 문장은 기쁨, 슬픔, 놀람, 분노, 혐오, 중립의 7개 감정을 라벨링 하였다. 데이터는 문장 열 - 감정라벨 열로 구성되어 있다.

해당 데이터의 구축 목적은 AIhub 내 텍스트 감정 인식 연구를 위한 데이터들이 대부분 긍정/부정으로만 분류되었다는 점에서, 다분류 감정에 대한 텍스트 데이터셋에 대한 수요를 충족하기 위함이라고 한다.

Sentence	Emotio
언니 동생으로 부르는게 맞는 일인가요..??	공포
그냥 내 느낌일뿐겠지?	공포
아직너무초기라서 그런거죠?	공포
유치원버스 사고 났다던데	공포
근데 원래이런거맞나요	공포
남자친구가 떠날까봐요	공포
이거 했는데 허리가 아플수도 있나요? ;;	공포

공포	54
놀람	58
분노	56
슬픔	52
중립	48
행복	60
혐오	54
Total	385

[그림 11] '한국어 감정 정보가 포함된 단발성 대화 데이터셋' 말뭉치 구조

3.1.4 성능검증용 데이터

성능검증에 사용한 데이터는 AI hub의 '감성 대화 말뭉치(v1.2, 2022-12-28)'로, 음성 15,700문장 및 코퍼스 27만 문장을 수집하여 크라우드 소싱을 통해 구축한 말뭉치 데이터이다. 일반인 1,500명을 대상으로 일상 대화 외에도 우울 정서가 내포된 대화 응답 시나리오와 우울증 환자 대상 Wizard of Oz Prototyping(WOZ) 대화 등의 콘텐츠를 수집함으로써 기존 사전학습 데이터 대비 감정적 속성이 강하게 드러나게 한 말뭉치이다.

감정 인식을 위한 데이터는 크롤링 등을 통한 데이터 수집이 불가능하여 직접 제작해야 하는 희소성 있는 데이터이며, 60가지의 감정을 다루고 있어 다양한 AI산업에 활용이 가능하다는 것이 강점이라고 소개하고 있다.

해당 데이터는 다양한 학습 모델 중 ALBERT 모델 학습을 감안하여 문장단위의 정제를 진행했으며, 의미 분별이 분명하도록 띄어쓰기, 복합어 처리, 숫자 처리, 외국어 처리 등의 과정을 수행하여 데이터셋 자체만으로 바로 학습이 가능하도록 하였다.

데이터는 [그림 12]와 같이 화자의 페르소나(연령, 성별, 신체질환), 상황 키워드, 감정 대분류(6가지), 감정 소분류(54가지) 및 대화 문장으로 구성되어 있다.

	연령	성별	상황키워드	신체질환	감정_대분류	감정_소분류	사람문장1	시스템문장1	사람문장2	시스템문장2	사람문장3	시스템문장3
1	청년	여성	진로,취업,직장	해당없음	분노	노여워하는	일은 왜 해도 해도 끝이 없을까않이 힘드시겠어요. 주위에 의 그냥 내가 해결하는 게 나아; 1혼자 해결하기로 했군요. 혼자서 해결하기 힘들면 주위에 의논할 사람을 찾아보세요.					
2	청년	여성	진로,취업,직장	해당없음	분노	노여워하는	이번 달에 또 급여가 깎였어! 1급여가 줄어 속상하시겠어요. 최대한 지출을 억제해야겠어. 월급이 줄어든 만큼 소비를 줄일 계획이군요.					
3	청년	여성	진로,취업,직장	해당없음	분노	노여워하는	회사에 신입이 들어왔는데 말!회사 동료 때문에 스트레스를 잘 안 맞는 사람이랑 억지로 5스트레스받지 않기 위해선 인간관계에 있어 약간의 거리를 두는 게 좋겠군요.					
4	청년	여성	진로,취업,직장	해당없음	분노	노여워하는	직장에서 텃새라는 이유로 나:관련 없는 심부름을 모두 하게 직장 사람들과 솔직하게 이야기직장 사람들과 이야기를 해 보겠다고 결심하셨군요.					
5	청년	여성	진로,취업,직장	해당없음	분노	노여워하는	얼마 전 입사한 신입사원이 나 무시하는 것 같은 태도에 화가상사인 나에게 먼저 인사하지 않상 먼저 인사하게 되어 화가 나셨군요. 어떻게 하면 신입사원에게 화났음을 표현할 수 있					
6	청년	여성	진로,취업,직장	해당없음	분노	노여워하는	직장에 다니고 있지만 시간만 진로에 대해서 고민하고 계시직장 상사한테 자주 지적을 받업무가 나와 맞지 않아 시간을 버리는 것 같이 느껴지셨군요.					
7	청년	여성	진로,취업,직장	해당없음	분노	노여워하는	성인인데도 진로를 아직도 못 부모님의 노여움에 십십하시군부모님께 좀 더 시간을 달라고 진로 테스트를 받아보겠다고 부모님께 말씀드릴 생각이군요.					
8	청년	여성	진로,취업,직장	해당없음	기쁨	느긋	퇴사한 지 얼마 안 됐지만 천천천천히라도 직장을 구해 보려;더 좋은 회사가 기다리고 있을 좋은 일자리를 놓치고 싶지 않아 잠잠없이 노력하시는군요. 하는 일이 잘 풀리시길 바라요.					
9	청년	여성	진로,취업,직장	해당없음	불안	걱정스러운	졸업반이라서 취업을 생각해야 취업에 대해 걱정이 되는군요. 응. 느긋함을 느끼는 내가 좀 ¿걱정보다는 느긋한 태도가 낫다고 생각하시는군요.					
10	청년	여성	진로,취업,직장	해당없음	기쁨	느긋	요즘 직장생활이 너무 편하고 직장생활이 편하고 좋으시다니. 우리 회사는 복지가 정말 좋아매번 얼마들에게는 정말 꿈의 회사인 것 같네요. 마음이 편하시겠어요.					
11	청년	여성	진로,취업,직장	해당없음	기쁨	느긋	취업해야 할 나이인데 취업이;취업하고 싶지 않으시군요. 혹 아직 조금 더 놀고 싶은 마음이직은 인생을 즐기고 싶은 마음이시군요.					
12	청년	여성	진로,취업,직장	해당없음	불안	당혹스러운	면접에서 부모님 직업에 대한 그때 어떤 생각이 들었나요? 무척 당혹스러웠어. 부모님 직 그런 면접 상황에 무척 놀라셨군요. 어떻게 답하셨는지 여쭤봐도 될까요?					
13	청년	여성	진로,취업,직장	해당없음	불안	당혹스러운	곤말이야. 부장님께 결재받아야 중요한 서류가 사라져서 당혹;혹시 과장님이 가져가신 건 아 혼이 날까 봐 과장님께 서류의 행방을 물어보는 것이 고민되시는군요.					

[그림 12] 말뭉치 데이터 구조

데이터의 감정 분류 기준은 대분류 6가지(분노, 슬픔, 불안, 상처, 당황, 기쁨)와 대분류에 해당하는 각각 9가지 세부 감정으로 구성되어 있으며 [표 14]와 같다.

[표 14] 감성 대화 말뭉치의 감정 분류 기준

	분노	슬픔	불안	상처	당황	기쁨
1	툴툴대는	실망한	두려운	질투하는	고립된	감사하는
2	좌절한	비통한	스트레스 받는	배신당한	남의 시선 의식하는	사랑하는
3	짜증나는	후회되는	취약한	고립된	외로운	편안한
4	방어적인	우울한	혼란스러운	충격 받은	열등감	만족스러운
5	악의적인	마비된	당혹스러운	불우한	죄책감	흥분되는
6	안달하는	염세적인	회의적인	희생된	부끄러운	느긋한
7	구역질 나는	눈물이 나는	걱정스러운	억울한	혐오스러운	안도하는
8	노여워 하는	낙담한	조심스러운	괴로워하는	한심한	신이 난
9	성가신	환멸을 느끼는	초조한	버려진	혼란스러운	자신하는

3.2 실험방법

본 연구는 감정분석 측면에서 세분화된 감정모델을 활용하고 담화의 흐름을 대상으로 한 감정 분류의 가능성 확인을 목적으로 한다. 기존의 감정분석 연구가 소수의 감정모델 활용 및 단문 단위의 텍스트 분석에 초점을 맞추었다면, 본 연구는 감정적 속성이 강한 데이터셋에 27가지의 감정모델을 반영하고 최종적으로 담화 단위에서의 감정 인식 여부에 중점을 두고 연구를 진행하고자 한다.

3.2.1 실험 개요

기존의 감정분석 연구는 비교적 짧은 단일문장을 대상으로 하여 공포, 기쁨, 혐오, 분노, 슬픔, 놀람의 6가지 감정을 기준으로 연구를 수행하였다. 본 연구에서는 기 분류된 학습용 데이터의 세분화 된 감정 라벨링을 수행하고, 이를 감정분석에 최적화 된 학습 알고리즘으로 사전학습 시킴으로써 기존 모델 대비 감정분류에 최적화 된 모델로 튜닝하였다. 튜닝된 모델을 기반으로 감정적 요소가 강하게 드러나는 담화데이터 를 활용하여 최종 성능을 검증하였다.

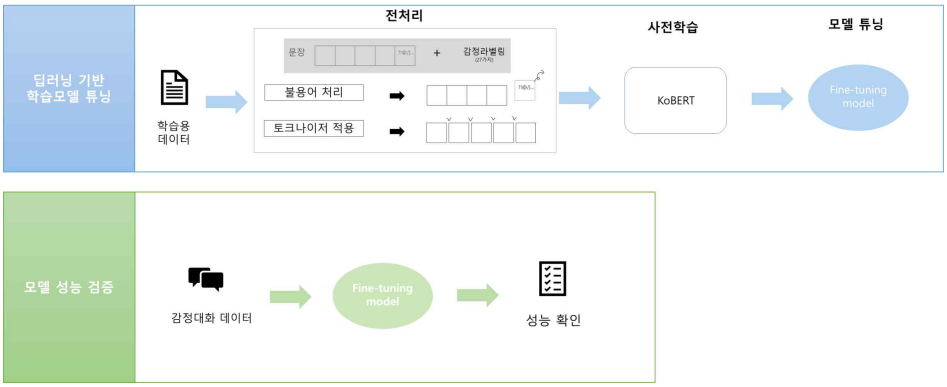

[그림 13] 실험과정

3.2.2 학습데이터 감정라벨 재분류

본 연구에서 사전학습 및 성능 검증에 사용된 데이터 뿐만 아니라 국내 감정 분류 연구에 활용되고 있는 데이터 대부분은 분류 기준이 되는 감정 모델이 불분명하거나, Ekman의 기본 6가지 감정을 활용하는 정도이다.

이러한 문제를 해결하기 위해 본 연구에서는 Alan Cowen의 다양한 감정 연구[7]를 종합하여 27가지의 고유한 감정을 제시한 'GoEmotion(D. Demszky et al., 2020)' 프로젝트의 감정분류 체계를 기준으로 채택하였다. 제시된 감정 목록은 [표 15]와 같다.

[표 15] D. Demszky et al.(2020)에 제시된 감정 분류체계

감정분류	한국어	의미(한국어)
admiration	감탄	인상적이거나 존경할 만한 것을 찾는 것
amusement	재미	재미있는 것을 찾거나 즐겁게 지내는 것
anger	분노	강한 불쾌감 혹은 반감
annoyance	짜증	가벼운 분노, 짜증
approval	인정	호의적인 의견을 가지거나 표현하는 것
caring	배려	다른 사람에 대한 친절과 관심을 나타내는 것
confusion	혼란	이해 부족, 불확실성
curiosity	호기심	무언가를 알거나 배우려는 강한 욕구
desire	갈망	무언가를 원하거나 어떤 일이 일어나기를 바라는 강한 느낌
disappointment	실망	자신의 희망이나 기대가 성취되지 않아서 생기는 슬픔이나 불쾌감
disgust	혐오	불쾌하거나 불쾌한 것에 의해 유발되는 혐오감 또는 강한 거부감
disapproval	반감	좋지 않은 의견을 가지고 있거나 표현하는 것
embarrassment	당혹감	자의식, 수치심 또는 어색함
excitement	흥분	큰 열정과 흥분을 느끼는 느낌
fear	두려움	두려움이나 걱정
gratitude	감사	감사하고 인정하는 느낌
grief	비통	특히 누군가의 죽음으로 인한 강렬한 슬픔
joy	기쁨	즐거움과 행복의 느낌
love	사랑	존중과 애정에 대한 강한 긍정적 감정
nervousness	걱정	염려, 걱정, 불안
optimism	낙관	미래 또는 어떤 일의 성공에 대한 희망과 자신감
pride	자랑스러움	자신의 업적이나 밀접한 사람들의 업적으로 인한 즐거움, 만족
realization	깨달음	무언가를 깨닫는 것
relief	안도	불안이나 고통에서 벗어난 후의 안심과 이완
remorse	회한	후회 또는 죄책감
sadness	슬픔	정서적 고통, 슬픔
surprise	놀라움	예상치 못한 일 등으로 놀라는 느낌

7) 짧은 동영상, 음악, 표정, 억양, 비언어적 음성 등을 통한 감정연구 (A. Cowen & Keltner, 2017), (A. Cowen et al., 2018), (A. Cowen et al., 2019), (A. Cowen et al., 2019a), (A. Cowen et al., 2019b)

3.1.2에서 소개한 '한국어 감정 정보가 포함된 단발성 대화 데이터셋'의 경우 Ekman의 기본 감정 외에 감정 속성이 상대적으로 덜 드러난 문장을 중립으로 분류하여 총 7가지 감정으로 문장을 분류하였다. 본 연구에서는 기존 7가지 감정 및 문장 키워드와 콘텐츠를 토대로 [표 16]과 같이 38,594개의 문장의 감정을 재분류하였다.

[표 16] 사전학습용 데이터 재분류 결과

감정분류(영문)	한국어	문장수
desire	갈망	82
gratitude	감사	666
admiration	감탄	494
nervousness	걱정	1639
joy	기쁨	2668
optimism	낙관	27
surprise	놀라움	46
embarrassment	당혹감	4926
fear	두려움	254
disapproval	반감	613
caring	배려	2346
anger	분노	1180
grief	비통	5663
love	사랑	35
sadness	슬픔	64
disappointment	실망	4024
relief	안도	48
approval	인정	59
realization	깨달음	414
pride	자랑스러움	113
amusement	재미	308
annoyance	짜증	33
disgust	혐오	1223
curiosity	호기심	384
confusion	혼란	2223
remorse	회한	47
excitement	흥분	159

3.1.3에서 소개한 '감성 대화 말뭉치' 역시 감정적 속성이 강한 일상대화를 콘텐츠로 하여 정제된 데이터를 구축하였다는 점에서 분명 희소성 있는 데이터지만, 분류 기준이 되는 감정모델이 불분명하고, 일부 소분류의 중복 등 몇 가지 문제를 발견하였다.

이에 본 연구에서는 Demszky et al. (2020)을 기준으로 하여 기 분류된 소분류 및 문장 내용을 토대로 [표 17]과 같이 51,630 세트 문장의 감정 라벨을 재분류 하였다.

[표 17] 성능검증용 데이터 재분류 결과

감정분류(영문)	한국어	문장세트
desire	갈망	875
gratitude	감사	709
admiration	감탄	105
nervousness	걱정	4631
joy	기쁨	1290
optimism	낙관	1861
surprise	놀라움	996
embarrassment	당혹감	2977
fear	두려움	3437
disapproval	반감	7342
caring	배려	22
anger	분노	2683
grief	비통	976
love	사랑	28
sadness	슬픔	9405
disappointment	실망	2805
relief	안도	842
approval	인정	18
realization	깨달음	5
pride	자랑스러움	669
amusement	재미	36
annoyance	짜증	1383
disgust	혐오	2599
curiosity	호기심	7
confusion	혼란	2261
remorse	회한	3108
excitement	흥분	560

3.2.3. 사전학습 데이터의 전처리

학습모델을 통해 데이터를 처리하기 위해서는 모델 세팅, 데이터 로딩, 학습용-테스트용 데이터 분류, 감정모델 세팅, 중복 데이터 및 불용어 처리, 토크나이저 적용 등의 선행과정이 필요하다.

모델 세팅은 개발 프레임워크에 모델을 로딩하고, 사용하고 있는 python 버전과 호환되는 라이브러리를 불러오는 과정이다. pip 명령어를 통해 모델 및 필요한 라이브러리를 로딩하였다. 실험에 활용된 라이브러리는 [표 18]과 같다

[표 18] 실험에 활용한 외부 라이브러리

라이브러리	설명
Pytorch	• Python 환경의 오픈소스 머신러닝 라이브러리
Transfomers	• Transformer 모델 적재, 학습 및 저장 가능한 API 제공
Gluonnlp	• 다수의 딥러닝 프레임워크에 관계없이 간편하게 딥러닝 모델을 구현하고 학습시키기 위한 표준 인터페이스
Mxnet	• 다양한 언어를 지원하고 모바일은 물론 네트워크 서버까지 지원하는 오픈소스 딥러닝 프레임워크
Pandas	• 데이터 분석 및 가공을 위한 python 기반 라이브러리
Numpy	• 다차원의 데이터 배열 및 수치 계산을 위한 python기반 라이브러리
Tqdm	• 터미널 혹은 노트북에서 코드 처리 및 진행상태를 시각적으로 표현해주는 라이브러리

감정모델 세팅은 모델 학습 과정에서 문장을 분류할 기준을 적용하는 과정이다. label_mapping 변수를 지정하여 0부터 26까지의 숫자열에 라벨링하고자 하는 27개의 감정을 매핑하는 과정을 거쳤다.

```python
# Label mapping. Note: Must start from "0".
label_mapping = {
    "분노": 0, "낙관": 1, "두려움": 2, "당혹감": 3, "슬픔": 4,
    "자랑스러움": 5, "혼란": 6, "반감": 7, "걱정": 8, "비통": 9,
    "안도": 10, "기쁨": 11, "실망": 12, "갈망": 13, "회한": 14,
    "혐오": 15, "흥분": 16, "놀라움": 17, "짜증": 18, "호기심": 19,
    "감사": 20, "재미": 21, "감탄": 22, "인정": 23, "배려": 24,
    "사랑": 25, "깨달음": 26
}
```

[그림 14] 감정모델 세팅

토크나이저 적용은 문장단위의 데이터를 분석이 가능한 형태소 단위로 쪼개는 과정이다. KoBERTTokenizer를 로딩한 후, BERTDataset 클래스를 정의하였다. 클래스는 Self-attention, 분석을 수행할 dataset, 문장 인덱스(sent_idx), 라벨 인덱스(label_idx), 분석할 문장의 최대 길이(max_len), tokenizer로 구성되었다. 분석을 위한 신경망 은닉층은 768개로 세팅하였다.

```python
# Define the BERTDataset class
class BERTDataset(Dataset):
    def __init__(self, dataset, sent_idx, label_idx, max_len, tokenizer):
        self.sentences = [tokenizer.encode(i[sent_idx], max_length=max_len,
                                           truncation=True) for i in dataset]
        self.labels = [i[label_idx] for i in dataset]
        self.max_len = max_len

    def __getitem__(self, i):
        # Right-pad the token_ids up to self.max_len
        token_ids = self.sentences[i] + [tokenizer.pad_token_id] * (self.max_len - len(self.sentences[i]))
        return torch.tensor(token_ids, dtype=torch.long), torch.tensor(self.labels[i], dtype=torch.long)

    def __len__(self):
        return len(self.labels)


# Define the BERTClassifier class
class BERTClassifier(nn.Module):
    def __init__(self, bert, hidden_size=768, num_classes=27, dr_rate=None):
        super(BERTClassifier, self).__init__()
        self.bert = bert
        self.classifier = nn.Linear(hidden_size, num_classes)
        self.dropout = nn.Dropout(p=dr_rate) if dr_rate else None

    def forward(self, token_ids):
        # Create an attention mask
        # Attention mask values are 1 for non-padding tokens and 0 for padding
        attention_mask = (token_ids != tokenizer.pad_token_id).float()

        # Pass the attention mask to the BERT model
        output = self.bert(input_ids=token_ids, attention_mask=attention_mask)
        pooled_output = output.pooler_output
        if self.dropout:
            pooled_output = self.dropout(pooled_output)
        return self.classifier(pooled_output)
```

[그림 15] 데이터셋 및 분류 클래스 적용

학습을 위한 데이터는 csv파일로 저장하여 구글 드라이브에 업로드하였고, 드라이브를 마운트하여 pandas의 pd.read_csv 명령어를 통해 불러왔다. 학습용 데이터와 테스트용 데이터는 각각 train_dataset과 test_dataset으로 정의하였으며, 학습-테스트 데이터의 비율은 2:8로 설정하였다.

3.3 사전학습

모델 사전학습을 위해 데이터를 학습 데이터와 테스트 데이터로 분류하고 하이퍼 파라미터(Hyper-parameter)를 조정하여 학습 컨디션을 설정하였다. 추후 검증용 데이터로 활용할 데이터의 길이를 감안하여 샘플 길이를 정하는 'max_len'은 512로 설정하였다.

```python
# Initialize tokenizer and model
tokenizer = KoBERTTokenizer.from_pretrained('skt/kobert-base-v1')
bert_model = BertModel.from_pretrained('skt/kobert-base-v1')

# Prepare datasets
max_len = 512
train_set, test_set = train_test_split(train_data[['Sentence', 'Emotion_2']].values.tolist(), test_size=0.2, random_state=4)

train_dataset = BERTDataset(train_set, 0, 1, max_len, tokenizer)
test_dataset = BERTDataset(test_set, 0, 1, max_len, tokenizer)

# Prepare data loaders
batch_size = 16
train_dataloader = DataLoader(train_dataset, batch_size=batch_size, shuffle=True)
test_dataloader = DataLoader(test_dataset, batch_size=batch_size)

# Define calc_accuracy function
def calc_accuracy(out, labels):
    predictions = torch.argmax(out, dim=1)
    correct = (predictions == labels).float()
    accuracy = correct.sum() / len(correct)
    return accuracy

# Set up the optimizer and scheduler
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
model = BERTClassifier(bert_model, dr_rate=0.5).to(device)
optimizer = AdamW(model.parameters(), lr=5e-5)
loss_fn = nn.CrossEntropyLoss()
```

[그림 16] 토크나이저 적용 및 하이퍼 파라미터 조정

전체 학습데이터 세트를 소그룹으로 나누어 학습할 데이터 수를 정하는 'Batch size'는 16, 학습데이터 세트가 신경망을 통과하는 횟수를 의미하는 'epochs'는 5, 학습을 진행하는 동안 신경망 모델이 각각의 가중치를 얼마나 업데이트할지 결정하는 'learning rate'는 5e-5로 설정하였다.

```python
from transformers import get_cosine_schedule_with_warmup

# Configuration
warmup_ratio = 0.1
num_epochs = 5
max_grad_norm = 1.0

# Create the learning rate scheduler
num_training_steps = len(train_dataloader) * num_epochs
num_warmup_steps = int(num_training_steps * warmup_ratio)
scheduler = get_cosine_schedule_with_warmup(optimizer, num_warmup_steps=num_warmup_steps, num_training_steps=num_training_steps)
```

[그림 17] 하이퍼 파라미터 조정(2)

사전학습은 총 5회의 epochs를 학습-테스트를 번갈아가며 한번씩 수행하고 각각의 정확도를 출력하는 방식으로 진행하였다.

```python
from tqdm import tqdm
torch.backends.cudnn.deterministic = True


# Training loop
for epoch in range(num_epochs):
    model.train()  # Tell the model to set itself to training mode
    train_acc = 0.0
    train_loss = 0.0

    for batch_id, (token_ids, labels) in enumerate(tqdm(train_dataloader, desc='Training')):
        token_ids = token_ids.to(device)
        labels = labels.to(device)

        optimizer.zero_grad()
        output = model(token_ids)  # Pass token_ids and the model will handle the attention mask


        loss = loss_fn(output, labels)
        loss.backward()
        torch.nn.utils.clip_grad_norm_(model.parameters(), max_grad_norm)
        optimizer.step()
        scheduler.step()  # Update learning rate schedule

        train_acc += calc_accuracy(output, labels)
        train_loss += loss.item()

    print(f"Epoch {epoch+1}/{num_epochs} | Train Loss: {train_loss/(batch_id+1)} | Train Accuracy: {train_acc/(batch_id+1)}")

    # Validation phase
    model.eval()
    test_acc = 0.0

    with torch.no_grad():
        for batch_id, (token_ids, labels) in enumerate(tqdm(test_dataloader, desc='Validation')):
            token_ids = token_ids.to(device)
            labels = labels.to(device)

            output = model(token_ids)  # Pass only token_ids
            test_acc += calc_accuracy(output, labels)

    print(f"Epoch {epoch+1}/{num_epochs} | Test Accuracy: {test_acc/(batch_id+1)}")
```

[그림 18] 사전학습 수행

3.4 모델 성능 검증

사전학습 모델과 동일한 환경에서 성능 검증을 진행하기 위해 사전학습 모델을 저장하는 과정을 거쳤다.

```
## 학습 모델 저장
PATH = 'content/drive/MyDrive/' # google 드라이브 연동 해야함. 관련코드는 뺐음
torch.save(model, PATH + 'KoBERT_27_emotion.pt')  # 전체 모델 저장
torch.save(model.state_dict(), PATH + 'model_state_dict.pt')  # 모델 객체의 state_dict 저장
torch.save({
    'model': model.state_dict(),
    'optimizer': optimizer.state_dict()
}, PATH + 'all.tar')  # 여러 가지 값 저장, 학습 중 진행 상황 저장을 위해 epoch, loss 값 등 일반 scalar값 저장 가능
```

[그림 19] 학습모델 저장

저장한 모델을 그대로 로딩하여 새로운 데이터셋을 적용한 후 사전학습과 같은 방식으로 학습-테스트를 수행하였다. 단, 이미 학습된 모델이고 데이터 크기로 인한 학습시간을 감안하여 epochs는 3회로 감소시켰다.

```
from transformers import get_cosine_schedule_with_warmup

# Configuration
warmup_ratio = 0.1
num_epochs = 3
max_grad_norm = 1.0

# Create the learning rate scheduler
num_training_steps = len(train_dataloader) * num_epochs
num_warmup_steps = int(num_training_steps * warmup_ratio)
scheduler = get_cosine_schedule_with_warmup(optimizer, num_warmup_steps=num_warmup_steps, num_training_steps=num_training_steps)
```

[그림 20] 학습컨디션 조절

제 4 장 실험결과

4.1 사전학습 결과

‘한국어 감정 정보가 포함된 단발성 대화 데이터셋’을 통한 사전학습 결과, 기존의 소규모 감정모델을 활용한 감정분류 연구 대비 분류 정확도는 낮은 편이었지만, 학습을 거칠수록 학습 및 테스트 과정의 분류 정확도가 향상하는 것을 확인할 수 있었다. 1차 학습의 정확도가 40.91%였다면, 5회차의 정확도가 89.13%로 무려 48.22%가 상승하였다. 테스트 과정의 정확도 역시 1회차 대비 5회차에서 약 4.4% 상승하였다.

[표 19] 사전학습 결과

epochs	Traning	Validation
1회	40.91%	58.15%
2회	61.55%	62.43%
3회	72.66%	63.56%
4회	82.58%	63.31%
5회	89.13%	62.55%

전체적인 분류 정확도를 확인 후, 각 감정별로 세부적인 분류 성능을 확인하기 위해 모델 성능 측정지표인 f1-score를 사용하였다. f1-score란, 정밀도(precision) 및 재현율(recall) 간의 조화평균으로, 모델 전체 성능이 아닌 class 별 성능을 자세히 분석하는 방식이다.

모델이 분류한 결과와 실제 정답간의 관계를 기반으로 실제 True인 정답을 True라고 예측하는 True Positive(TP), 실제 False인 정답을 False라고 예측하는 True Negative(TN), 실제 False인 정답을 True로 예측하는 False Positive(FP), 실제 True인 정답을 False라고 예측하는 False Negative(FN)으로 나누어 각 샘플의 비율을 계산한다. 모델이 분류한 결과와 실제 정답 간의 관계는 [표 19]와 같다.

[표 20] 모델의 분류와 정답

		실제 정답	
		True	False
분류결과	True	True Positive	False Positive
	False	False Negative	True Negative

- True Positive(TP) : 실제 True인 정답을 True라고 예측 (정답)
- False Positive(FP) : 실제 False인 정답을 True라고 예측 (오답)
- False Negative(FN) : 실제 True인 정답을 False라고 예측 (오답)
- True Negative(TN) : 실제 False인 정답을 False라고 예측 (정답)

정밀도(Precision)는 분류 모델 성능 평가 지표로, 모델이 True로 예측한 샘플 중 실제 True인 샘플의 비율을 나타낸다. 즉, 정밀도는 모델의 입장에서 정답을 정답이라고 맞춘 경우에 중점을 두는 것이다. 산식은 다음과 같다.

$$(Precision) = \frac{TP}{TP + FP}$$

재현율(Recall)은 실제로 True인 결과 중에서 모델이 True로 예측한 샘플의 비율을 나타낸다. 재현율은 실제 데이터의 입장에서 정답을 정답이라고 맞춘 경우에 중점을 둔다. 산식은 다음과 같다.

$$(Recall) = \frac{TP}{TP + FN}$$

사전학습 데이터 분석에 따른 정밀도, 재현율 및 f1-score 계산 결과는 [표 20]과 같다.

[표 21] 감정별 분류 성능

감정분류		Precision	Recall	f1-score
긍정	갈망	0.50	0.17	0.25
긍정	감사	0.92	0.95	**0.93**
긍정	감탄	0.69	0.66	0.67
긍정	기쁨	0.71	0.66	0.68
긍정	깨달음	0.00	0.00	0.00
긍정	낙관	0.86	0.35	0.50
긍정	놀라움	0.58	0.61	0.60
긍정	배려	0.85	0.91	**0.88**
긍정	사랑	0.54	0.58	0.56
긍정	안도	0.88	0.58	0.70
긍정	인정	0.71	0.85	0.77
긍정	자랑스러움	0.77	0.42	0.54
긍정	재미	0.79	0.66	0.72
긍정	호기심	0.52	0.44	0.47
긍정	흥분	0.68	0.60	0.64
부정	걱정	0.68	0.69	0.68
부정	당혹감	0.33	0.10	0.15
부정	두려움	0.57	0.53	0.55
부정	반감	0.30	0.32	0.31
부정	분노	0.71	0.69	0.70
부정	비통	0.00	0.00	0.00
부정	슬픔	0.64	0.69	0.67
부정	실망	0.00	0.00	0.00
부정	짜증	0.67	0.80	**0.73**
부정	혐오	0.58	0.56	0.57
부정	혼란	0.50	0.52	0.51
부정	회한	0.33	0.20	0.25

분류 데이터 수가 많을수록 성능이 높게 나왔으며, 혹여 데이터가 많지 않더라도 분류 기준이 될 수 있는 명확한 키워드가 있는 감정(예 : 감사, 배려, 짜증) 등의 경우 분류 성능이 상대적으로 높게 나왔다. ‘반감’의 경우 학습데이터 숫자가 많은 편임에도 한국 정서 특성상 부정 표현이 명확하게 드러나지 않는 경우(예 : 누가 이런걸 돈주고 사냐? 등)가 많아 상대적으로 분류 성능이 좋지 않은 것을 확인할 수 있다. ‘누군가의 죽음 등으로 인한 강렬한 슬픔’을 나타내는 ‘비통’ 역시 슬픔의 세부 강도에 대한 기준이 명확하지 않아서인지 분류 자체가 되지 않았다.

‘자신의 희망이나 기대가 성취되지 않아서 생기는 슬픔이나 불쾌감’을 나타내는 ‘실망’ 역시 희망이나 기대의 성취 여부를 판단할 수 있는 기준이 모호하여 분류가 어려운 것으로 판단된다.

사전학습 이후, 기존 KoBERT모델과 비교했을 때 Classifier가 생성된 것을 확인할 수 있었으며, 이를 통해 모델 임베딩 및 신경망 통과 이후 문맥 분석을 거쳐 분류기로 들어가는 과정으로 감정분류가 수행된다는 것을 확인하였다.

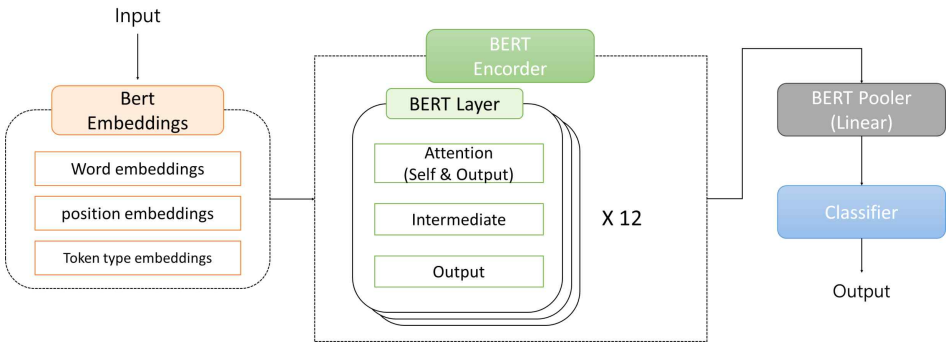

[그림 21] 사전학습 후 KoBERT 모델 변화

4.2 모델 성능검증 결과

모델 성능검증을 위한 장문의 감성대화 데이터셋 학습 결과, 단문 중심의 사전학습 데이터 성능 대비 다소 저조한 수치를 기록하였으나, 어느 정도는 분류가 수행되는 것을 확인할 수 있었으며, 학습을 반복함에 따라 정확도가 올라가는 것 또한 확인할 수 있었다.

[표 22] 대화 데이터를 통한 모델 성능 검증 결과

epochs	Traning	Validation
1회	46.21%	55.34%
2회	57.37%	59.45%
3회	63.53%	59.98%

epochs를 3회만 수행하였음에도 어느 정도 분류가 가능한 점을 미루어보았을 때, 학습횟수 및 감정단어사전 추가 등의 방법으로 분류 성능을 높일 수 있을 것으로 기대한다.

[표 23] 감정별 분류 성능

감정분류		Precision	Recall	f1-score
긍정	갈망	0.70	0.14	0.23
긍정	감사	0.73	0.76	**0.75**
긍정	감탄	0.00	0.00	0.00
긍정	기쁨	0.52	0.65	0.57
긍정	깨달음	0.00	0.00	0.00
긍정	낙관	0.56	0.67	0.61
긍정	놀라움	0.68	0.64	**0.66**
긍정	배려	0.00	0.00	0.00
긍정	사랑	0.00	0.00	0.00
긍정	안도	0.64	0.55	0.59
긍정	인정	0.00	0.00	0.00
긍정	자랑스러움	0.50	0.46	0.48
긍정	재미	0.00	0.00	0.00
긍정	호기심	0.00	0.00	0.00
긍정	흥분	0.70	0.20	0.32
부정	걱정	0.58	0.70	0.63
부정	당혹감	0.62	0.67	0.65
부정	두려움	0.60	0.54	0.57
부정	반감	0.60	0.58	0.59
부정	분노	0.54	0.60	0.57
부정	비통	0.76	0.33	0.46
부정	슬픔	0.62	0.75	**0.68**
부정	실망	0.62	0.46	0.53
부정	짜증	0.58	0.66	0.62
부정	혐오	0.66	0.41	0.51
부정	혼란	0.66	0.50	0.57
부정	회한	0.54	0.60	0.57

제 5 장 결론

5.1 결론 및 시사점

본 연구는 기존의 딥러닝 기반 감정분석 연구 대비 감정적 요소가 강하게 드러나는 데이터를 대상으로 다수의 감정모델을 적용함으로써, 인간의 다양한 감정에 대한 기계의 인지 및 분류 가능성을 확인하는 과정이었다. 이를 위해 기존 데이터셋의 6가지 감정을 27개로 재분류하고, 이를 바탕으로 한국어 BERT모델 중 하나인 KoBERT모델을 가지고 사전학습을 수행함으로써 감정자질에 대한 분류 성능을 강화하였다.

딥러닝 기반의 감정분석 실험 자체는 워낙 널리 알려진 방식이고 많은 연구자들이 시도했던 연구이지만, 감정적 요소가 상대적으로 적은 데이터 혹은 단문 중심의 데이터를 적은 수의 감정만을 가지고 분류하는 케이스가 대부분이었다. 이에 본 연구는 감정적 요소가 강하게 드러나는 데이터를 기반으로 다양한 감정을 분류할 수 있도록 모델 튜닝과정을 거친 후 인간의 실제 감정적 대화를 활용하여 성능을 확인하고자 하였다.

사전학습 및 성능검증 결과 27가지의 감정 중에서 분류 기준에 따라 명확한 키워드가 존재하는 감사, 배려, 짜증의 감정에서는 분류 성능이 높게 나왔으나, 반감, 비통, 실망 등에 대해서는 상대적으로 분류 성능이 저하되는 것을 확인하였다. 이는 KoBERT 모델 내 vocab 개수가 8천개 정도로 매우 적은 편이며, 관형어나 설의법 등 다양한 한국어 문맥에 대한 학습이 충분히 이루어지지 않았기 때문인 것으로 판단된다.

향후 우리의 삶에서 많은 부분을 차지할 메타버스 등 가상세계에서는 인간 대 인간뿐만 아니라 인간과 기계 사이의 원활한 소통도 중요해질 것이다. 대상이 인간이든 기계든 원활한 소통을 위해서는 상대의 감정을 파악하는 것이 최우선 과제이다. 인간의 감정을 인식하고 감정 인식을

증강시키기 위해서는 인간 감정에 대한 이해가 필요하며, 그 방법론을 마련하는 것이 선행되어야 한다. 그러한 측면에서 본 연구는 다양한 인간 감정을 기계에 인식시키기 위한 연구방법론을 마련했다는 점에서 의미가 있다고 볼 수 있다.

5.2 연구의 한계 및 향후 연구 발전방향

5.2.1 연구의 한계

4장의 연구결과에서 언급하였듯, 사전학습 모델이 27개의 감정을 100% 분류할 수 있는 것은 아니었다. 감정 키워드가 명확한 문장이 아닐 경우 분류 성능이 저하되거나 아예 분류가 불가능한 현상을 확인할 수 있었다. 이는 감정단어 사전을 통해 해결할 수 있지만, 결정적으로 단어 단위로 토크나이징 하여 단어 간 상관관계 중심으로 분석하다 보니 문장이 길어지거나 한국어 특유의 설의법적 특성이 강한 문장을 분류하기에는 부족하였다.

또한, 기존 데이터셋을 27개의 감정 모델로 분류하는 과정에서도 어려움이 존재했다. Ekman을 비롯한 기존의 감정연구자들이 '보편적 감정'으로 언급했던 6가지 감정은 국가나 민족 간 차이를 초월한 공통감정이지만, Cowen의 연구를 종합하여 설정한 D. Demszky et al.(2020)의 감정 모델은 한국 정서와 다소 맞지 않는 부분이 존재했다. 가령, '사촌이 땅을 사면 배가 아프다'는 한국 속담을 반영하기라도 하듯, 학습데이터 속 문장에 유난히 타인을 부러워하거나 질투하는 내용이 다수 존재하였는데, 본 연구에서 활용한 분류체계에서는 '질투'로 분류할 수 있는 감정이 없었다.

5.2.2 향후 연구방향

본 연구는 한국어 처리 성능에 특화되었다는 점에서 KoBERT를 적용하여 연구를 수행하였지만, 감정 키워드가 명확한 단어 외에도 문맥분석 등을 적용할 수 있으려면 다양한 자연어 처리 모델을 적용하여 모델 간 성능을 비교하는 과정이 필요하였다. 그러한 측면에서 향후 KoBERT 모델 외 다양한 한국어 BERT 모델과 BERT 외 모델들을 적용하여 성능을 비교하고자 한다. 아울러, 한국의 문화와 정서에 부합하며 한국인 대화에

최적화된 감정모델을 정립하여 라벨링하는 방법론을 탐색할 예정이다.

또한, 본 연구는 비정형 데이터 중에서도 텍스트 데이터를 중심으로 연구를 수행하였다. 하지만 원활한 소통을 위해서는 텍스트 뿐만 아니라 음성, 표정, 제스처 등 다양한 언어적·비언어적 요소가 병행되어야 한다. 이를 위해 추후에는 음성과 텍스트, 혹은 표정과 음성, 텍스트 등 멀티모달 연결 데이터를 다양한 감정모델에 적용하여 분류하는 방향으로 연구를 발전시킬 예정이다.

참고문헌

[1] Hyunjae Lee, Jaewoong Yoon, Bonggyu Hwang, Seongho Joe, Seungjai Min, Youngjune Gwon, KoreALBERT: Pretraining a Lite BERT Model for Korean Language Understanding, arXiv preprint arXiv: 2101.11363, 2021.01.27

[2] Jiwon Hyeon, Joonil Lee, Hyunkwon Cho, Sentiment Analysis of News on Corporation Using KoBERT, Korean Accounting Review, Vol.47, No.4, 33 ~ 54, 2022

[3] Sangah Lee, Hansol Jang, Yunmee Baik, Suzi Park, Hyopil Shin, KR-BERT: A Small-Scale Korean-Specific Language Model, arXiv preprint arXiv: 2008.03979, 2020.08.10

[4] Younghyun Chi, Jang Hyun Kim, Seungjong Sun, Korean Language NLP Model Based Emotional Analysis of LGBTQ Social Media Communities, 2023 17th International Conference on Ubiquitous Information Management and Communication (IMCOM), 2023.02.08

[5] 권재일, 의사소통 능력의 향상 방안, 텍스트언어학, Vol. 54, 5 ~ 26, 2023

[6] 김경훈, 박진욱, 이지은, 박상현, SMERT: 감성 분석 및 감정 탐지를 위한 단일 입출력 멀티 모달 BERT, 한국정보과학회, Vol.47, No.10, 1122 ~ 1131, 2021.10

[7] 김명규, 김정호, 차명훈, 채수환, 텍스트 문서 기반의 감성 인식 시스템, 감성과학, Vol. 12, No. 4, 443 ~ 442, 2009.12

[8] 김명숙&김지연, 텍스트 마이닝 기법을 이용한 인터넷전문은행 사용자의 관심 분석, K Business Management Journal, Vol.7, No.1, 163~176, 2023.02.22

[9] 김윤하, 전윤수, 김준우, 김남규, 도메인 특화 사전학습 언어모델 개발 전략: 자동차 분야 언어모델 V-BERT 개발 사례, 정보과학회 컴퓨팅의 실제 논문지, Vol. 29, No.5, 228 ~ 239, 2023.05

[10] 김은성, 주수빈, 이찬형, 전수영, QA 신경망 모델을 이용한 영미시 감정 분류, Journal of the Korean Data Analysis Society, Vol.24, No.2, 585 ~ 597, 2022.04

[11] 김재훈, 박소현, 한경식, 국내 주요 온라인 커뮤니티의 혐오 표현 사용 양상에 관한 연구, 한국HCI학회, Vol.18, No.1, 27 ~ 36, 2023.03

[12] 나은경&진가아, 컴퓨터 매개 커뮤니케이션 시대의 사랑과 연애: 대학생 연인 간 텍스트, 음성, 화상, 면대면 소통이 연애 관계의 질에 미치는 영향, 커뮤니케이션학 연구 : 일반, Vol. 30, No.2, 5 ~ 39, 2022.05.28

[13] 박소연&정의현, AI 안면감정인식과 텍스트 감성분석 기술을 적용한 학습자 만족도 평가 사례 연구, The Korean Journal of Human Resource Development Quarterly, Vol.24, No.4, 65 ~ 86, 2022

[14] 박용익, 의사소통능력 개발을 위한 대화분석 연구의 활용과 그것의 언어학적 의미 : 기업 커뮤니케이션을 예로, 텍스트언어학, Vol.17, 453 ~ 480, 2004

[15] 박정원, 모현수, 김정민, 좌충우돌 감성분석 BERT 미세조정 분석, 한국컴퓨터정보학회 동계학술대회 논문집, Vol.19, No.1, 13 ~ 15, 2021.01

[16] 박정하, 배동석, 조경신, 박정원, 김아름, 양상운, 한국어 음성 및 텍스트 데이터의 의미적 정확성 품질검증 방법, 한국통신학회 하계종합학술발표회, 1101 ~ 1102, 2023

[17] 박준규&손경아, 감정 분석을 위한 그래프 순위화 기반 강인한 한국어 BERT 모델, 한국컴퓨터종합학술대회, 797 ~ 799, 2020.07

[18] 박호연&김경재, CNN-LSTM 조합모델을 이용한 영화리뷰 감성 분석, 지능정보연구, Vol.25, No.4, 141 ~ 154, 2019.12

[19] 신동원, 이연수, 장정선, 임해창, CNN-LSTM을 이용한 대화 문맥 반영과 감정 분류, 제28회 한글 및 한국어 정보처리 학술대회 논문집, 141 ~ 146, 2016.10

[20] 안명숙, 서바이벌 드라마 '오징어 게임'에 대한 시청자 감성 연구 : 소셜미디어 빅데이터 감성분석 중심으로, Journal of Literary therapy, Vol.63, 213 ~ 252, 2022.04

[21] 윤경섭&오종민, 딥러닝 모델(BERT)과 감정 어휘 사전을 결합한 음원 가사 감정 분석, 한국컴퓨터정보학회 하계학술대회 논문집, Vol.30, No.2, 471 ~ 474, 2022.07

[22] 윤정우&남지순, 자질기반 감성분석 모델 학습을 위한 주석데이터셋 FeSAD 구축 방법론, 언어연구, Vol. 37, No.3, 335 ~ 358, 2021.11.15

[23] 윤태일&변혜영, 지속가능성 보고서의 CEO 메시지에 대한 감정 분석, Journal of Public Relations, Vol.27, No.1, 153 ~181, 2023.03

[24] 이상아&신효필, 감정 분석을 위한 BERT 사전학습모델과 추가 자질 모델의 결합, 한국정보과학회, Vol.48, No.7, 815 ~ 824, 2021.07

[25] 이승호&정유남, 딥러닝을 활용한 비윤리 텍스트 데이터 분석, Journal of korean Culture (JKC), Vol. 60, 63 ~ 100, 2023.02.28

[26] 이준범, KcBERT: 한국어 댓글로 학습한 BERT, 2020년도 제32회 한글 및 한국어 정보처리 학술대회, 437 ~ 440, 2020.10.14

[27] 임준호, 김현기, 김영길, 딥러닝 사전학습 언어모델 기술 동향, 전자통신동향분석, Vol.35, No.3, 9 ~ 19, 2020.06

[28] 임칠성, 디지털 소통과 화용론 연구의 과제, 국어교과교육연구, Vol. 30, 7 ~ 26, 2017

[29] 장연지, 최지선, 김한샘, 감정 어휘 사전을 활용한 KcBert 기반 영화 리뷰 말뭉치 감정 분석, 한국정보과학회, Vol.49, No.8, 608 ~ 616, 2022.08

[30] 조국현, 텍스트종류‘ 영화평’의 매체적 변이 : 영화 ‘국제시장’과 ‘그래비티’를 사례로, 독어학, Vol. 34, 253 ~ 273, 2016.12.10

[31] 조국현, 의사소통적 억압 : 공감과 합의의 의사소통을 위한 언어학적 소고, 텍스트언어학, Vol. 44, 181 ~ 204, 2018

[32] 조국현, 의사소통 위험, 텍스트언어학, Vol.17, 403 ~ 428, 2004

[33] 천현득, 인공 지능에서 인공 감정으로 : 감정을 가진 기계는 실현 가능한가?, 철학, Vol. 131, 217 ~ 243, 2017.05

[34] 편지윤, AI 알고리즘 기반 텍스트 환경에서 비판적 리터러시에 대한 단상, 국어교육연구, Vol. 79, 36 ~ 76, 2022.06.20

[35] 한재호, 김우정, 한경식, 인터넷 뉴스 댓글 기반의 다중 감정 분석모델 개발 및 적용, PROCEEDINGS OF HCI KOREA 2018 학술대회 발표 논문집, 893 ~ 897, 2018.01

[36] 현지원, 이준일, 조현권, KoBERT를 이용한 기업관련 신문기사 감성 분류 연구, 회계학연구, Vol.47, No.4, 33 ~ 54, 2022.08

[37] 황창회, 유광훈, 남지순, DECO 언어자원・의존 파서와 LSTM에 기반한 하이브리드 자질기반 감성분석 플랫폼 연구, 언어연구, Vol. 36, No.4, 525 ~ 552, 2021.02.08

[38] Alan Cowen, Disa Sauter, Jessica L. Tracy, Dacher Keltner, Mapping the Passions: Toward a High-Dimensional Taxonomy of Emotional Experience and Expression, Psychological Science in the Public Interest, Vol.20, No.1, 69~90, 2019.07.17

[39] Ankush Chatterjee, Umang Gupta, Manoj Kumar Chinnakotla, Radhakrishnan Srikanth, Michel Galley, Puneet Agrawal, Understanding Emotions in Text Using Deep Learning and Big Data, Computers in Human Behavior, Vol.93, 309 ~ 317, 2019.04

[40] Asad Abdi, Siti Mariyam Shamsuddin, Shafaatunnur Hasan, Jalil Piran, Deep learning-based sentiment classification of evaluative text based on Multi-feature fusion, Information Processing & Management, Vol.56, No.4, 1245 ~ 1259, 2019.07

[41] Bernhard Kratzwald, Suzana Ilić, Mathias Kraus, Stefan Feuerriegel, Helmut Prendinger, Deep learning for affective computing: Text-based emotion recognition in decision support, Decision Support Systems, Vol.115, 24 ~ 35, 2018.11

[42] Bing Liu, Sentiment Analysis and Opinion Mining, 2012.05

[43] Bo Pang, Lillian Lee, Opinion mining and sentiment analysis, Foundations and Trends in Information Retrieval, Vol.2, No.1-2, 1 ~ 135, 2008

[44] Doaa Mohey El-Din Mohamed Hussein, A survey on sentiment analysis challenges, Journal of King Saud University - Engineering Sciences, Vol.30, No.4, 330 ~ 338, 2018.10

[45] Dorottya Demszky, Dana Movshovitz-Attias, Jeongwoo Ko, Alan Cowen, Gaurav Nemade, Sujith Ravi, GoEmotions: A Dataset of Fine-Grained Emotions, arXiv preprint arXiv: 2005.00547, 2020.06.03

[46] Francisca Adoma Acheampong, Henry Nunoo-Mensah & Wenyu Chen, Transformer models for text-based emotion detection: a review of BERT-based approaches, Artificial Intelligence Review, Vol.54, 5789 ~ 5829, 2021.02.08

[47] Guixian Xu; Yueting Meng; Xiaoyu Qiu; Ziheng Yu; Xu Wu, Sentiment Analysis of Comment Texts Based on BiLSTM, IEEE Access, Vol.7, 51522 ~ 51532, 2019.04.29

[48] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova, BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding, arXiv preprint arXiv:1810.04805, 2018

[49] James A. Russell, A Circumplex Model of Affect, Journal of Personality and Social Psychology, Vol.39, No.6, 1161 ~ 1178, 1980.12

[50] Jiawen Deng, Fuji Ren, A Survey of Textual Emotion Recognition and Its Challenges, IEEE TRANSACTIONS ON AFFECTIVE COMPUTING, Vol.14, No.1, 49 ~ 67, 2023.02.28

[51] Jin Wang , Liang-Chih Yu, K. Robert Lai, Xuejie Zhang, Tree-Structured Regional CNN-LSTM Model for Dimensional Sentiment Analysis, IEEE/ACM Transactions on Audio, Speech, and Language Processing, Vol.28, 581 ~ 591, 2019.12.11

[52] Kashfia Sailunaz, Reda Alhajj, Emotion and sentiment analysis from Twitter text, Journal of Computational Science, Vol.36, 2019.09

[53] Kevin Clark, Minh-Thang Luong, Quoc V. Le, Christopher D. Manning, ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators, arXiv preprint arXiv: 2003.10555, 2020.03.23

[54] Maite Taboada, Julian Brooke, Milan Tofiloski, Kimberly Voll, Manfred Stede, Lexicon-Based Method for Sentiment Analysis, Computational linguistics, Vol.37, No.2, 267 ~ 307, 2010.09.28

[55] MANSUR ALP TOCOGLU, OKAN OZTURKMENOGLU, ADIL ALP KOCAK, Emotion Analysis From Turkish Tweets Using Deep Neural Networks, IEEE Access, Vol.7, 61~69, 2019.12.26

[56] Manzil Zaheer, Guru Guruganesh, Kumar Avinava Dubey, Joshua Ainslie, Chris Alberti, Santiago Ontanon, Philip Pham, Anirudh Ravula, Qifan Wang, Li Yang, Amr Ahmed, Big Bird: Transformers for Longer Sequences, arXiv preprint arXiv: 2007.14062, 2020.07

[57] Myriam Munezero, Calkin Suero Montero, Erkki Sutinen, John Pajunen, Are They Different? Affect, Feeling, Emotion, Sentiment, and Opinion Detection in Text, IEEE TRANSACTIONS ON AFFECTIVE COMPUTING, Vol.5, No.2, 101 ~ 111, 2014.04.13

[58] Myung-Jin Lim, Moung-Ho Yi, Ju-Hyun Shin, Intrinsic Emotion Recognition Considering the Emotional Association in Dialogues, Electronics, Vol.12, No.2, 2023.01.08

[59] Nikita Kitaev, Łukasz Kaiser, Anselm Levskaya, Reformer: The Efficient Transformer, arXiv preprint arXiv: 2001.04451, 2020.01.13

[60] Nourah Alswaidan, Mohamed El Bachir Menai, A survey of state-of-the-art approaches for emotion recognition in text, Knowledge and Information Systems, Vol.62, 2937 ~ 2987, 2020.03.18

[61] Pansy Nandwani & Rupali Verma, A review on sentiment analysis and emotion detection from text, Social Network Analysis and Mining, Vol.11, 2021.08.28

[62] Paul Ekman, Facial Expressions of Emotion: New Findings, New Questions, Psychological Science, Vol.3, No.1, 34 ~ 38, 1992.01

[63] Paul Ekman, An Argument for Basic Emotions, Cognition and Emotion, Vol.6, 169~200, 1992

[64] Paul R. Kleinginna JR., Anne M. Kleinginna, A Categorized List of Emotion Definitions, with Suggestions for a Consensual Definition, Motivation and Emotion, Vol.5, No.4, 345 ~ 379, 1981

[65] Philip J. Stone, Dexter C. Dunphy, Marchall S. Smith, Daniel M. Ogilvie, The General Inquirer : A Computer Approach to Content Analysis, The M.I.T Press, 1966

[66] Praphula Kumar Jain, Vijayalakshmi Saravanan, Rajendra Pamula, A Hybrid CNN-LSTM: A Deep Learning Approach for Consumer Sentiment Analysis Using Qualitative User-Generated Contents, ACM Transactions on Asian and Low-Resource Language Information Processing, Vol.20, No.5, 1 ~ 15, 2021.07.21

[67] Ranjan Kumar Behera, Monalisa Jena, Santanu Kumar Rath, Sanjay Misrad, Co-LSTM: Convolutional LSTM model for sentiment analysis in social big data, Information Processing & Management, Vol.58, No.1, 2021.01

[68] Raymond B. Cattell, Sentiment or attitude? The core of a terminology problem in personality research, Jounal of Personality, Vol.9, No.1, 6 ~ 17, 1940

[69] Samira Zad, Maryam Heidari, James H Jr Jones, Ozlem Uzune, Emotion Detection of Textual Data: An Interdisciplinary Survey, 2021 IEEE World AI IoT Congress(AIIoT), 2021.05

[70] Sancheng Peng, Lihong Cao, Yongmei Zhou, Zhouhao Ouyang, Aimin Yang, Xinguang Li, Weijia Jia, Shui Yu, A survey on deep learning for textual emotion analysis in social networks, Digital Communications and Networks, Vol.8, No.5, 745 ~ 762, 2022.10

[71] TIANCHENG TANG, XINHUAI TANG, TIANYI YUAN, Fine-Tuning BERT for Multi-Label Sentiment Analysis in Unbalanced Code-Switching Text, IEEE Access, Vol. 8, 193248 ~ 193256, 2020.10.12

[72] Victor Sanh, Lysandre Debut, Julien Chaumond, Thomas Wolf, DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter, arXiv preprint arXiv: 1910.01108, 2019.10.02

[73] Walaa Medhat, Ahmed Hassan, Hoda Korashy, Sentiment analysis algorithms and applications:A survey, Ain Shams Engineering Journal, Vol.5, 1093 ~ 1113, 2014.05.27

[74] William James, What is an Emotion?, Oxford University Press on behalf of the Mind Association, Vol.9, No. 34, 188~205, 1884.04

[75] Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, Veselin Stoyanov, RoBERTa: A Robustly Optimized BERT Pretraining Approach, arXiv preprint arXiv: 1907.11692, 2019.06.26

[76] Zhaoxia Wang, Seng-Beng Ho & Erik Cambria, A review of emotion sensing: categorization models and algorithms, Multimedia Tools and Applications, Vol.79, 35553 ~ 35582, 2020.01.03

[77] Zhenzhong Lan, Mingda Chen, Sebastian Goodman, Kevin Gimpel, Piyush Sharma, Radu Soricut, ALBERT: A Lite BERT for Self-supervised Learning of Language Representations, arXiv preprint arXiv: 1909.11942, 2019.09.26